

Sistem Informasi Peringatan Dini Proaktif Berbasis Machine Learning untuk Penyakit Hipertensi

Proposal Tugas Akhir

Oleh

**Samuel Franciscus Togar Hasurungan
18222131**



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
Oktober 2025**

LEMBAR PENGESAHAN

Sistem Informasi Peringatan Dini Proaktif Berbasis Machine Learning untuk Penyakit Hipertensi

Proposal Tugas Akhir

Oleh

Samuel Franciscus Togar Hasurungan
18222131

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Proposal Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 29 Oktober 2025

Pembimbing

Prof. Dr. Ir. Suhono Harso Supangkat, M.Eng.
NIP. 196212031988111001

DAFTAR ISI

DAFTAR GAMBAR	iv
DAFTAR TABEL	v
DAFTAR KODE	vi
I PENDAHULUAN	1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	2
I.3 Tujuan	3
I.4 Batasan Masalah	3
I.5 Metodologi	4
II STUDI LITERATUR	6
II.1 Krisis Hipertensi	6
II.1.1 Hipertensi Urgensi (Hypertensive Urgency)	6
II.1.2 Hipertensi Emergensi (Hypertensive Emergency)	6
II.1.3 Faktor Pemicu Utama	7
II.1.4 Prosedur Diagnostik	7
II.1.5 Prinsip Tatalaksana Hipertensi Emergensi	7
II.2 Konsep Digital Twin dalam Kesehatan	8
II.3 Landasan Pemodelan Prediktif Klinis	9
II.3.1 Sumber Data dan Pra-pemrosesan	9
II.3.2 Feature Engineering	9
II.4 Model Machine Learning dan Evaluasi	10
II.4.1 Metrik Evaluasi	10
II.5 Explainable AI (XAI) dalam Medis	10
II.6 Penelitian Terkait dan Posisi Penelitian	11
III ANALISIS MASALAH	13
III.1 Analisis Kondisi Saat Ini	13
III.2 Analisis Kebutuhan	13
III.2.1 Identifikasi Masalah Pengguna	13
III.2.2 Kebutuhan Fungsional	14
III.2.3 Kebutuhan Nonfungsional	14
III.3 Analisis Pemilihan Solusi	14

III.3.1 Alternatif Solusi	14
III.3.2 Analisis Penentuan Solusi	14
IV DESAIN KONSEP SOLUSI	16
V RENCANA SELANJUTNYA	17

DAFTAR GAMBAR

DAFTAR TABEL

DAFTAR KODE

BAB I

PENDAHULUAN

I.1 Latar Belakang

Hipertensi merupakan tantangan kesehatan masyarakat global dan faktor risiko utama yang berkontribusi pada morbiditas dan mortalitas akibat penyakit kardiovaskular, seperti stroke dan gagal jantung (Reges et al., 2020). Data WHO (2023) mengindikasikan bahwa 1,28 miliar orang dewasa di seluruh dunia hidup dengan hipertensi, sebuah angka yang sejalan dengan tingginya prevalensi di Indonesia.

Permasalahan fundamental dalam manajemen hipertensi saat ini terletak pada paradigmanya yang bersifat reaktif. Intervensi klinis sering kali baru dilakukan setelah diagnosis ditegakkan atau setelah terjadi fluktuasi tekanan darah (TD) yang signifikan (Savoia et al., 2017; Carey et al., 2018).. Kelemahan dari pendekatan reaktif ini adalah kegagalannya dalam mengantisipasi dan mencegah episode akut yang paling berbahaya yaitu krisis hipertensi. Kondisi darurat medis ini terjadi ketika tekanan darah sistolik dan diastolik melebihi 180/120 mmHg, yang secara langsung berpotensi menyebabkan kerusakan pada organ target (Talle et al., 2023).

Peluang untuk transisi menuju manajemen proaktif kini terbuka melalui pemanfaatan machine learning (ML) pada data runtun waktu (time-series) klinis. Dataset publik beresolusi tinggi, seperti MIMIC-IV (Medical Information Mart for Intensive Care), menyediakan rekaman data vital sign seperti nilai TD per jam, dan intervensi medis secara longitudinal (Johnson et al., 2023). Data ini memungkinkan pelatihan model prediktif. Secara khusus, model ensemble seperti Random Forest (RF) atau XGBoost telah menunjukkan performa state-of-the-art dalam menangani data tabular kompleks yang dihasilkan dari proses feature engineering pada data runtun waktu untuk memprediksi luaran klinis (S et al., 2024; Izonin et al., 2024).

Meskipun demikian, akurasi prediktif yang tinggi (high-fidelity) saja belum men-

cukupi untuk adopsi klinis. Hambatan utama dalam implementasi machine learning di lingkungan berisiko tinggi seperti perawatan kesehatan adalah sifat "black box". Masalah "black box" pada machine learning di bidang kesehatan merujuk pada kurangnya transparansi dan interpretabilitas dari model-model kompleks seperti deep learning, sehingga sulit bagi klinisi dan pasien untuk memahami alasan di balik prediksi atau rekomendasi yang dihasilkan (Poon & Sung, 2021; Rudin, 2018). Model-model ini sering kali kurang memiliki transparansi internal karena meskipun mampu menghasilkan prediksi (output) yang akurat, model tersebut tidak dapat memberikan justifikasi yang mudah dipahami manusia atas keputusan yang diambil (Elshaw et al., 2019). Kurangnya transparansi internal pada model dapat menghambat kepercayaan dan akuntabilitas, sehingga penting untuk mengembangkan sistem yang memungkinkan penelusuran dan verifikasi alasan di balik setiap rekomendasi atau peringatan otomatis (Visco et al., 2023).

Untuk mengatasi kesenjangan antara akurasi dan interpretabilitas ini, disiplin Explainable AI (XAI) menjadi sangat krusial. Metode XAI, khususnya metode atribusi post-hoc seperti SHAP (SHapley Additive exPlanations), menawarkan solusi yang kuat. SHAP, yang didasarkan pada teori permainan kooperatif, mampu mengkal-kulasi kontribusi spesifik dari setiap fitur masukan terhadap deviasi prediksi model dari nilai dasarnya (Khan et al., 2024; Ali et al., 2023). Pendekatan ini secara efektif memberikan penjelasan yang terukur mengenai alasan di balik terbentuknya suatu prediksi tertentu (Nohara et al., 2021).

Oleh karena itu, penelitian ini mengusulkan pengembangan Digital Twin berbasis data sebagai purwarupa sistem pendukung keputusan klinis (CDSS) yang dirancang untuk memadukan akurasi dan transparansi. Konsep ini merujuk pada model yang digerakkan oleh algoritma machine learning seperti Random Forest dan XGBoost, bukan pada simulasi fisiologis mekanistik yang bersifat menyeluruh. Melalui integrasi antara model prediktif yang andal dan metode penjelasan SHAP, penelitian ini bertujuan menjembatani kesenjangan dalam adopsi sistem cerdas dengan menghadirkan alat yang mampu memberikan peringatan tentang apa yang diprediksi sekaligus menjelaskan alasan di balik prediksi tersebut.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah dalam penelitian ini adalah:

1. Bagaimana merancang proses feature engineering untuk mengubah data runtun waktu (time-series) berfrekuensi tinggi dari MIMIC-IV menjadi set fitur

tabular yang relevan untuk memprediksi krisis hipertensi?

2. Bagaimana mengembangkan dan mengevaluasi model machine learning (XGBoost/RF) untuk mencapai akurasi prediksi risiko krisis hipertensi jangka pendek yang optimal?
3. Bagaimana mengimplementasikan metode SHAP untuk menganalisis model yang telah dilatih dan memberikan penjelasan yang dapat ditafsirkan (interpretable) untuk setiap prediksi risiko individu?
4. Bagaimana Purwarupa Digital Twin Hipertensi berbasis machine learning dapat dirancang untuk menampilkan hasil prediksi dan rasionalisasi SHAP secara user-friendly bagi pengguna?

I.3 Tujuan

Tujuan utama pelaksanaan Tugas Akhir ini adalah:

1. Mengekstraksi kohort pasien yang relevan dan membangun pipeline feature engineering untuk memproses data runtun waktu dari MIMIC-IV.
2. Mengembangkan dan memvalidasi model prediktif (XGBoost/RF) yang akurat untuk memberikan peringatan dini (early warning) krisis hipertensi.
3. Mengaplikasikan SHAP untuk mengidentifikasi faktor-faktor klinis utama/fitur yang paling berkontribusi terhadap prediksi risiko tinggi, sehingga memberikan transparansi pada keluaran model.
4. Merancang dan membangun Purwarupa Digital Twin sederhana dan interaktif untuk mendemonstrasikan hasil prediksi dan rasionalisasi SHAP secara user-friendly bagi pengguna.

I.4 Batasan Masalah

Batasan-batasan masalah yang diambil dalam pelaksanaan tugas akhir ini adalah sebagai berikut:

1. Penelitian ini berfokus pada perancangan, pengembangan, dan evaluasi purwarupa dalam lingkungan simulasi. Penelitian ini tidak mencakup implementasi klinis di rumah sakit atau uji coba prospektif pada pasien nyata.
2. Sumber data difokuskan namun tidak terbatas pada dataset publik anonim MIMIC-IV. Kohort pasien berasal dari lingkungan ICU, sehingga generalisasi model ke populasi hipertensi umum (rawat jalan) memerlukan validasi lebih lanjut.
3. Model Digital Twin yang dimaksud penulis merujuk pada model prediktif berbasis data (XGBoost/RF), bukan model simulasi fisiologis mekanistik yang

komprehensif.

4. Eksplorasi model terbatas pada algoritma Machine Learning. Metode Explainable AI yang diimplementasikan adalah SHAP (SHapley Additive Explanations) namun kajian lebih dalam untuk validasi tetap diperlukan.
5. Keluaran sistem adalah skor risiko dan penjelasan fitur (SHAP values), yang berfungsi sebagai pendukung keputusan, bukan sebagai diagnosis medis otomatis.

I.5 Metodologi

Penelitian ini menggunakan pendekatan kuantitatif dengan desain studi berupa pemodelan komputasi dan analisis data sekunder. Alur penelitian (research workflow) dirancang secara sistematis dalam beberapa tahapan utama yang saling berurutan untuk mencapai tujuan yang telah ditetapkan. Tahapan-tahapan tersebut akan dielaborasi secara rinci dalam Bab 3, namun secara garis besar adalah sebagai berikut:

1. **Studi Literatur dan Akuisisi Data** Tahap awal penelitian mencakup studi literatur mendalam mengenai hipertensi, krisis hipertensi, arsitektur Digital Twin di bidang kesehatan, model machine learning (khususnya XGBoost/RF), dan implementasi Explainable AI (XAI) menggunakan SHAP. Secara paralel, dilakukan proses akuisisi data dengan mengakses dan mengunduh dataset anonim MIMIC-IV dari PhysioNet, setelah memenuhi persyaratan etika data.
2. **Pra-Pemrosesan dan Ekstraksi Kohort** Data mentah MIMIC-IV yang berukuran sangat besar akan diproses. Tahap ini berfokus pada:
 - Ekstraksi Kohort: Mendefinisikan kriteria inklusi dan eksklusi (misalnya, pasien dewasa dengan diagnosis hipertensi, ketersediaan data vital sign minimal 24 jam) untuk menyaring dan memilih populasi studi yang relevan.
 - Pembersihan Data: Menangani data yang hilang (missing values), data yang tidak konsisten, dan normalisasi data.
3. **Feature Engineering** Ini adalah tahap krusial untuk mengubah data runtun waktu (time-series) berfrekuensi tinggi menjadi format data tabular yang statis dan siap digunakan oleh model ML. Proses ini mencakup ekstraksi fitur-fitur yang relevan secara klinis, seperti fitur agregat (misal, rata-rata, min, maks TD dalam 3 jam), fitur tren (misal, slope atau kemiringan grafik TD dalam 1 jam terakhir), dan fitur temporal (misal, waktu sejak pemberian obat anti-hipertensi terakhir).
4. **Pengembangan Model Prediktif** Pada tahap ini, data tabular yang telah bersih dibagi menjadi data latih (training set) dan data uji (testing set). Model

ensemble (diprioritaskan XGBoost atau Random Forest) akan dilatih menggunakan data latih untuk memprediksi target outcome yang telah didefinisikan (misalnya, probabilitas terjadinya krisis hipertensi dalam N jam ke depan).

5. **Evaluasi Kinerja dan Analisis Penjelasan (XAI)** Model yang telah dilatih akan dievaluasi kinerjanya menggunakan data uji dengan metrik standar seperti Area Under the Receiver Operating Characteristic Curve (AUC-ROC), Akurasi, Presisi, dan Recall. Setelah model divalidasi, metode SHAP akan diaplikasikan untuk:
 - Secara Global: Mengidentifikasi fitur apa yang paling berpengaruh secara umum terhadap prediksi model (SHAP Summary Plot).
 - Secara Lokal: Menganalisis prediksi individu untuk memahami kontribusi spesifik setiap fitur pada kasus pasien tertentu (SHAP Force Plot).
6. **Perancangan Purwarupa dan Visualisasi** Sebagai tahap akhir, sebuah purwarupa (prototype) dashboard visualisasi sederhana akan dikembangkan (misalnya menggunakan Streamlit atau Dash). Dashboard ini akan mensimulasikan fungsionalitas Digital Twin dengan menampilkan prediksi risiko (output model) beserta penjelasannya (output SHAP) secara interpretable.

BAB II

STUDI LITERATUR

II.1 Krisis Hipertensi

Krisis Hipertensi merupakan suatu kondisi medis serius yang ditandai oleh peningkatan tekanan darah (TD) akut yang parah. Kondisi ini umumnya didefinisikan ketika Tekanan Darah Sistolik (TDS) melebihi 180 mmHg atau Tekanan Darah Diastolik (TDD) melebihi 120 mmHg (StatPearls 2025; Mayo Clinic 2022). Identifikasi dan tatalaksana segera sangat penting untuk mencegah kerusakan organ permanen atau risiko kematian (StatPearls 2025). Krisis ini diklasifikasikan berdasarkan keberadaan kerusakan organ target akut yang dimediasi oleh hipertensi atau HMOD, membaginya menjadi Hipertensi Urgensi dan Hipertensi Emergensi (Cleveland Clinic 2024; StatPearls 2025).

II.1.1 Hipertensi Urgensi (Hypertensive Urgency)

Hipertensi Urgensi ditandai dengan peningkatan TD yang parah yaitu TD sistolik melebihi 180 mmHg dan TD diastolik melebihi 120 mmHg tanpa adanya tanda-tanda kerusakan organ target akut yang baru atau progresif (StatPearls 2023). Gejala yang mungkin dialami pasien dalam kondisi urgensi cenderung non-spesifik, mencakup sakit kepala berkepanjangan, mimisan, pusing, atau kegelisahan (MSF 2025; Cleveland Clinic 2024). Karena ketiadaan kerusakan organ akut, tatalaksana diarahkan pada penurunan tekanan darah secara bertahap dalam kurun waktu 24 hingga 48 jam, umumnya menggunakan medikasi oral (StatPearls 2025).

II.1.2 Hipertensi Emergensi (Hypertensive Emergency)

Hipertensi Emergensi adalah kondisi yang mengancam jiwa dan memerlukan intervensi segera (BMJ Best Practice 2024). Kondisi ini dicirikan oleh TD yang sangat tinggi yaitu TD sistolik melebihi 180 mmHg dan TD diastolik melebihi 120 mmHg

yang disertai bukti kerusakan organ target akut. Kerusakan organ yang dapat terjadi meliputi sistem saraf, yang dapat memunculkan perubahan status mental, kebingungan, atau perubahan penglihatan. Selain itu, kerusakan juga dapat terjadi pada jantung, memicu gagal jantung atau infark miokard, ginjal yang menyebabkan gagal ginjal akut, serta pembuluh darah besar, misalnya diseksi aorta atau aneurisma (StatPearls 2024; AHA 2025).

II.1.3 Faktor Pemicu Utama

Salah satu penyebab paling umum krisis hipertensi pada pasien dengan riwayat hipertensi kronis adalah *ketidakpatuhan pasien*, yang berarti kegagalan mengikuti jadwal dan dosis pengobatan antihipertensi yang diresepkan (MDPI 2022; StatPearls 2025). Faktor pemicu lain meliputi kondisi seperti preeklampsia atau eklampsia dalam kehamilan, adanya penyakit ginjal, serta penggunaan obat-obatan yang dapat meningkatkan TD, misalnya obat antiinflamasi nonsteroid atau stimulan seperti kokain (MSF 2025; StatPearls 2024).

II.1.4 Prosedur Diagnostik

Evaluasi pasien dengan kecurigaan krisis hipertensi harus dilakukan dengan cepat untuk menentukan keberadaan kerusakan organ target (StatPearls 2024). Rangkaian tes diagnostik yang direkomendasikan mencakup:

1. Pemeriksaan laboratorium, seperti Hitung Darah Lengkap, Panel Metabolik Lengkap untuk menilai fungsi ginjal, dan enzim jantung seperti Troponin serta BNP untuk menilai cedera miokard (BMJ Best Practice 2024).
2. Pemeriksaan urin untuk mengevaluasi fungsi ginjal (BMJ Best Practice 2024).
3. Pemeriksaan pencitraan dan jantung: EKG dilakukan untuk menilai irama jantung, sedangkan Rontgen Dada dapat mendeteksi gagal jantung kongestif (BMJ Best Practice 2024).
4. Jika ada gejala neurologis seperti nyeri kepala hebat, CT scan kepala diindikasikan untuk menyingkirkan perdarahan intrakranial atau stroke (StatPearls 2024).

II.1.5 Prinsip Tatalaksana Hipertensi Emergensi

Tatalaksana pada Hipertensi Emergensi membutuhkan rawat inap dan pengawasan intensif, seringkali di ICU, serta pemberian obat antihipertensi secara intravena (BMJ Best Practice 2024). Tujuan utama terapi adalah mengurangi tekanan darah secara bertahap dan terkontrol untuk mencegah hipoperfusi pada organ yang telah

terbiasa dengan TD tinggi kronis (ACCP 2018). Penurunan TD yang terlalu cepat harus dihindari karena berisiko memicu iskemia serebral, koroner, atau ginjal (BMJ Best Practice 2024). Untuk target penurunan umum, pedoman klinis merekomendasikan penurunan Tekanan Arteri Rerata atau MAP tidak lebih dari 20% hingga 25% dalam jam pertama (StatPearls 2024; BMJ Best Practice 2024). Setelahnya, TD diturunkan secara bertahap menuju 160/100-110 mmHg dalam waktu 2 hingga 6 jam berikutnya (BMJ Best Practice 2024).

II.2 Konsep Digital Twin dalam Kesehatan

Konsep Digital Twin, yang berasal dari industri manufaktur, merujuk pada representasi virtual atau kembaran digital dari sebuah objek, proses, atau sistem fisik. Kembaran digital ini diperbarui secara dinamis menggunakan data real-time dari mitra fisiknya, memungkinkannya untuk melakukan pemantauan, analisis, dan simulasi (Emmert-Streib & Yli-Harja, 2024).

Dalam konteks kesehatan, Digital Twin berevolusi menjadi model virtual personal dari pasien. Model ini mengintegrasikan data pasien multi-modal, termasuk data fisiologis, demografis, dan riwayat klinis, untuk mensimulasikan status kesehatan individu.

Terdapat dua pendekatan utama dalam membangun Digital Twin kesehatan:

1. Model mekanistik, yang mencoba mensimulasikan fisiologi manusia secara komprehensif menggunakan persamaan diferensial dan prinsip-prinsip biologi.
2. Model data-driven atau berbasis data, yang menjadi fokus penelitian ini.

Penelitian ini mendefinisikan "*Digital Twin Sederhana*" sebagai sebuah purwarupa sistem interaktif yang intinya ditenagai oleh model machine learning (Laubenbacher et al., 2022). Model ini tidak mensimulasikan seluruh biologi, melainkan belajar dari pola data historis untuk memprediksi *outcome* spesifik dan memungkinkan simulasi intervensi "*what-if*" berbasis data. Penerapan konsep ini terbukti relevan untuk manajemen penyakit kronis, di mana model Digital Twin telah dieksplorasi untuk memprediksi kadar glukosa pada pasien diabetes atau memantau risiko gagal jantung, menunjukkan potensinya dalam menyediakan peringatan dini yang dipersonalisasi.

II.3 Landasan Pemodelan Prediktif Klinis

Pengembangan model data-driven ini mengikuti alur kerja penemuan pengetahuan yang sistematis. Alur kerja standar dalam data science, sering disebut sebagai *Knowledge Discovery in Databases (KDD)*, menyediakan kerangka kerja metodologis yang formal. Proses KDD terdiri dari beberapa tahapan inti yang iteratif: Seleksi Data, Pra-pemrosesan, Transformasi, Data Mining (Pemodelan), dan Evaluasi atau Interpretasi (Fayyad et al., 1996). Setiap tahap memiliki peran krusial dalam membangun model yang valid dan andal.

II.3.1 Sumber Data dan Pra-pemrosesan

Penelitian ini memanfaatkan dataset *MIMIC-IV* (Medical Information Mart for Intensive Care) sebagai sumber data. MIMIC-IV adalah *database* publik berskala besar yang berisi data rekam medis elektronik de-identifikasi dari pasien yang dirawat di unit perawatan intensif (ICU) di Beth Israel Deaconess Medical Center (Johnson et al., 2023). Relevansi *dataset* ini terletak pada ketersediaan data vital sign beresolusi tinggi, yang dicatat dalam tabel *chartevents*. Data ini memungkinkan pelacakan fluktuasi tekanan darah dari jam ke jam, yang merupakan prasyarat mutlak untuk membangun model peringatan dini proaktif.

II.3.2 Feature Engineering

Tahap Transformasi, atau *Feature Engineering*, adalah langkah fundamental dalam alur kerja ini. Model *machine learning* klasik seperti XGBoost tidak dapat memproses data runtun waktu (*time-series*) mentah secara langsung; mereka memerlukan input dalam bentuk tabel fitur yang statis. Oleh karena itu, teknik *feature engineering* diperlukan untuk mengekstrak informasi prediktif dari data runtun waktu (Shickel et al., 2018). Ini melibatkan penerapan *sliding window* (jendela geser) pada data historis pasien (misalnya, data 12 jam terakhir) untuk mengkalkulasi variabel atau fitur baru. Fitur-fitur ini dapat berupa:

- statistik agregat seperti "mean_TD_3jam" (rata-rata tekanan darah 3 jam terakhir),
- fitur tren seperti "slope_TD_1jam" (kemiringan grafik tekanan darah 1 jam terakhir), atau
- fitur temporal seperti "waktu_sejak_obat_terakhir".

Kualitas dari fitur-fitur inilah yang akan menentukan kinerja dari model prediktif.

II.4 Model Machine Learning dan Evaluasi

Inti dari proses **data mining** adalah pemilihan dan penerapan algoritma **machine learning**. Penelitian ini berfokus pada *model ensemble*, yang dikenal karena kinerjanya yang tinggi. Model **ensemble** menggabungkan prediksi dari beberapa model yang lebih lemah untuk menghasilkan satu prediksi akhir yang kuat. Dua metode **ensemble** yang paling populer adalah *Random Forest* dan *XGBoost* (**Extreme Gradient Boosting**) (Chen & Guestrin, 2016). XGBoost seringkali menunjukkan kinerja superior pada data tabular terstruktur seperti yang akan dihasilkan dari proses **feature engineering**. Keunggulannya terletak pada kemampuannya menangani data yang hilang (*missing values*) secara internal dan regularisasi yang kuat untuk mencegah **overfitting**.

II.4.1 Metrik Evaluasi

Karena target luaran adalah prediksi risiko krisis hipertensi (masalah klasifikasi biner), evaluasi kinerja tidak bisa hanya bergantung pada metrik akurasi, terutama pada data medis yang seringkali tidak seimbang (*imbalanced*). Metrik evaluasi yang lebih relevan akan digunakan, seperti:

- *Precision* (kemampuan model untuk tidak salah memberi alarm palsu).
- *Recall* (kemampuan model untuk menemukan semua kasus krisis yang sebenarnya).
- *F1-Score*.

Secara khusus, *Area Under the Receiver Operating Characteristic Curve (AUC-ROC)* akan digunakan sebagai metrik evaluasi utama. AUC-ROC mengukur kemampuan diskriminatif model secara keseluruhan, yaitu seberapa baik model dapat membedakan antara pasien yang akan mengalami krisis dan yang tidak, terlepas dari ambang batas prediksi yang dipilih (Jeni et al., 2013).

—

II.5 Explainable AI (XAI) dalam Medis

Masalah fundamental dengan model **ensemble** yang kuat seperti XGBoost adalah sifatnya sebagai *"kotak hitam"* (*black box*). Model ini dapat menghasilkan prediksi yang sangat akurat, namun proses pengambilan keputusannya sangat kompleks dan tidak dapat dipahami secara intuitif oleh manusia. Dalam domain berisiko tinggi seperti kedokteran, akurasi saja tidak cukup (Ahmad et al., 2021). Kebutuhan akan kepercayaan (*trust*), transparansi, dan akuntabilitas (*accountability*) menjadikan

Explainable AI (XAI) sebagai komponen wajib.

Implementasi *SHAP* akan menghasilkan dua jenis penjelasan utama yang krusial untuk purwarupa Digital Twin:

1. *Interpretabilitas Global* (SHAP Summary Plot): Menunjukkan fitur apa saja, seperti "slope_TD_1jam", yang memiliki dampak paling besar secara keseluruhan pada prediksi model.
2. *Interpretabilitas Lokal* (SHAP Force Plot atau Waterfall Plot): Menjelaskan secara rinci mengapa satu prediksi spesifik dibuat untuk satu pasien individu pada satu waktu tertentu.

Kemampuan untuk memberikan alasan di balik setiap peringatan inilah yang mengubah model prediktif menjadi sistem pendukung keputusan yang dapat dipercaya.

II.6 Penelitian Terkait dan Posisi Penelitian

Penelitian ini berada di persimpangan tiga domain riset aktif: pemodelan prediktif di ICU, *ensemble learning*, dan XAI. Tinjauan pustaka menunjukkan bahwa *dataset* MIMIC-IV telah banyak digunakan untuk pemodelan prediktif, tetapi fokusnya seringkali pada luaran lain seperti prediksi sepsis, mortalitas di ICU, atau kejadian hipotensi (Rahman et al., 2021). Studi-studi ini memvalidasi penggunaan MIMIC-IV untuk pemodelan runtun waktu, namun menyisakan celah pada prediksi spesifik krisis hipertensi.

Kombinasi XGBoost dan SHAP telah muncul sebagai *state-of-the-art* untuk membangun model klinis yang interpretable, terbukti dalam memprediksi luaran kardiovaskular seperti mortalitas pasca-infark miokard (Jia et al., 2023).

Kebaruan (*novelty*) dan posisi penelitian ini terletak pada sintesis unik dari ketiga domain tersebut:

- *Fokus Spesifik*: Fokus secara spesifik pada *prediksi risiko krisis hipertensi* di lingkungan ICU, sebuah masalah kritis yang sering terabaikan.
- *Horizon Waktu*: Mengembangkan dan membandingkan model pada beberapa horizon waktu (misalnya, prediksi jangka pendek N -jam vs. jangka menengah M -jam), yang akan memberikan wawasan klinis lebih dalam.
- *Kontribusi Utama*: Pengembangan purwarupa Digital Twin fungsional yang menyajikan peringatan dini yang *dapat dijelaskan dan ditindaklanjuti* (*explainable and actionable insights*) secara *real-time* (tersimulasi) menggunakan

SHAP.

BAB III

ANALISIS MASALAH

III.1 Analisis Kondisi Saat Ini

Menurut **laudon2020**<empty citation>, gambarkan terlebih dahulu model konseptual sistem yang ada saat ini. Model konseptual ini berisi berbagai komponen atau subsistem dan interaksi antarsubsistem tersebut. Setelah itu, berikan penjelasan tentang masalah yang ada pada sistem tersebut. Paragraf berikut berisi contoh penjabaran masalah sistem informasi fasilitas kesehatan untuk pasien (**pressman2019**).

III.2 Analisis Kebutuhan

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

III.2.1 Identifikasi Masalah Pengguna

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

III.2.2 Kebutuhan Fungsional

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

III.2.3 Kebutuhan Nonfungsional

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

III.3 Analisis Pemilihan Solusi

III.3.1 Alternatif Solusi

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Donec odio elit, dictum in, hendrerit sit amet, egestas sed, leo. Praesent feugiat sapien aliquet odio. Integer vitae justo. Aliquam vestibulum fringilla lorem. Sed neque lectus, consectetur at, consectetur sed, eleifend ac, lectus. Nulla facilisi. Pellentesque eget lectus. Proin eu metus. Sed porttitor. In hac habitasse platea dictumst. Suspendisse eu lectus. Ut mi mi, lacinia sit amet, placerat et, mollis vitae, dui. Sed ante tellus, tristique ut, iaculis eu, malesuada ac, dui. Mauris nibh leo, facilisis non, adipiscing quis, ultrices a, dui.

III.3.2 Analisis Penentuan Solusi

Morbi luctus, wisi viverra faucibus pretium, nibh est placerat odio, nec commodo wisi enim eget quam. Quisque libero justo, consectetur a, feugiat vitae, porttitor eu, libero. Suspendisse sed mauris vitae elit sollicitudin malesuada. Maecenas ultricies eros sit amet ante. Ut venenatis velit. Maecenas sed mi eget dui varius euismod.

Phasellus aliquet volutpat odio. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Pellentesque sit amet pede ac sem eleifend consetetuer. Nullam elementum, urna vel imperdiet sodales, elit ipsum pharetra ligula, ac pretium ante justo a nulla. Curabitur tristique arcu eu metus. Vestibulum lectus. Proin mauris. Proin eu nunc eu urna hendrerit faucibus. Aliquam auctor, pede consequat laoreet varius, eros tellus scelerisque quam, pellentesque hendrerit ipsum dolor sed augue. Nulla nec lacus.

BAB IV

DESAIN KONSEP SOLUSI

Ilustrasikan desain konsep solusi dalam bentuk model konseptual dan penjelasan secara ringkas, beserta perbedaannya dengan sistem saat ini. Ilustrasi harus dapat dibandingkan (*before and after*). Karena masih berupa proposal, bab ini hanya berisi gambar desain konsep solusi tersebut dan penjelasan perbandingannya dengan gambar sistem yang ada saat ini (yang tergambar di awal Bab III).

BAB V

RENCANA SELANJUTNYA

Jelaskan secara detail langkah-langkah rencana selanjutnya, hal-hal yang diperlukan atau akan disiapkan, dan risiko dan mitigasinya, yang meliputi:

1. Rencana implementasi, termasuk alat dan bahan yang diperlukan, lingkungan, konfigurasi, biaya, dan sebagainya.
2. Desain pengujian dan evaluasi, misalnya metode verifikasi dan validasi.
3. Analisis risiko dan mitigasi, misalnya tindakan selanjutnya jika ada yang tidak berjalan sesuai rencana.