

Pengembangan Sistem Prediksi Risiko Hipertensi Menggunakan Machine Learning Terinterpretasi (SHAP) dan Chatbot Berbasis LLM-RAG

Proposal Tugas Akhir

Oleh

**Samuel Franciscus Togar Hasurungan
18222131**



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
Nopember 2025**

LEMBAR PENGESAHAN

Sistem Informasi Peringatan Dini Proaktif Berbasis Machine Learning untuk Penyakit Hipertensi

Proposal Tugas Akhir

Oleh

Samuel Franciscus Togar Hasurungan
18222131

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Proposal Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 19 Nopember 2025

Pembimbing

Prof. Dr. Ir. Suhono Harso Supangkat, M.Eng.
NIP. 196212031988111001

DAFTAR ISI

DAFTAR GAMBAR	iv
DAFTAR TABEL	v
DAFTAR KODE	vi
I PENDAHULUAN	1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	2
I.3 Tujuan	3
I.4 Batasan Masalah	3
I.5 Metodologi	4
II STUDI LITERATUR	6
II.1 Krisis Hipertensi	6
II.1.1 Hipertensi Urgensi (Hypertensive Urgency)	6
II.1.2 Hipertensi Emergensi (Hypertensive Emergency)	6
II.1.3 Faktor Pemicu Utama	7
II.1.4 Prosedur Diagnostik	7
II.1.5 Prinsip Tatalaksana Hipertensi Emergensi	7
II.2 Konsep Digital Twin dalam Kesehatan	8
II.3 Landasan Pemodelan Prediktif Klinis	9
II.3.1 Sumber Data dan Pra-pemrosesan	9
II.3.2 Feature Engineering	9
II.4 Model Machine Learning dan Evaluasi	10
II.4.1 Metrik Evaluasi	10
II.5 Explainable AI (XAI) dalam Medis	10
II.6 Penelitian Terkait dan Posisi Penelitian	11
III ANALISIS MASALAH	13
III.1 Analisis Kondisi Saat Ini	13
III.1.1 Analisis Kesenjangan	15
III.2 Analisis Kebutuhan	17
III.2.1 Identifikasi Masalah Pengguna	17
III.2.2 Kebutuhan Fungsional	18
III.2.3 Kebutuhan Nonfungsional	19

III.3 Analisis Pemilihan Solusi	20
III.3.1 Alternatif Solusi	21
III.3.2 Analisis Penentuan Solusi	23
III.3.3 Solusi Terpilih	24
IV DESAIN KONSEP SOLUSI	25
V RENCANA SELANJUTNYA	26

DAFTAR GAMBAR

III.1 Alur proses 'As-Is' manajemen klinis hipertensi	13
---	----

DAFTAR TABEL

III.1 Analisis Kesenjangan (Gap Analysis)	16
III.2 Kebutuhan Fungsional	19
III.3 Kebutuhan Nonfungsional	20
III.4 Pemetaan Masalah	21
III.5 Pemetaan Peluang (Proyek Hipertensi)	22
III.6 Alternatif Solusi	23
III.7 Pemilihan Solusi dengan Weighted Scoring Model (WSM)	24

DAFTAR KODE

BAB I

PENDAHULUAN

I.1 Latar Belakang

Hipertensi merupakan tantangan kesehatan masyarakat global dan faktor risiko utama yang berkontribusi pada morbiditas dan mortalitas akibat penyakit kardiovaskular, seperti stroke dan gagal jantung (Reges et al., 2020). Data WHO (2023) mengindikasikan bahwa 1,28 miliar orang dewasa di seluruh dunia hidup dengan hipertensi, sebuah angka yang sejalan dengan tingginya prevalensi di Indonesia.

Permasalahan fundamental dalam manajemen hipertensi saat ini terletak pada paradigmanya yang bersifat reaktif. Intervensi klinis sering kali baru dilakukan setelah diagnosis ditegakkan atau setelah terjadi fluktuasi tekanan darah (TD) yang signifikan (Savoia et al., 2017; Carey et al., 2018).. Kelemahan dari pendekatan reaktif ini adalah kegagalannya dalam mengantisipasi dan mencegah episode akut yang paling berbahaya yaitu krisis hipertensi. Kondisi darurat medis ini terjadi ketika tekanan darah sistolik dan diastolik melebihi 180/120 mmHg, yang secara langsung berpotensi menyebabkan kerusakan pada organ target (Talle et al., 2023).

Peluang untuk transisi menuju manajemen proaktif kini terbuka melalui pemanfaatan machine learning (ML) pada data runtun waktu (time-series) klinis. Dataset publik beresolusi tinggi, seperti MIMIC-IV (Medical Information Mart for Intensive Care), menyediakan rekaman data vital sign seperti nilai TD per jam, dan intervensi medis secara longitudinal (Johnson et al., 2023). Data ini memungkinkan pelatihan model prediktif. Secara khusus, model ensemble seperti Random Forest (RF) atau XGBoost telah menunjukkan performa state-of-the-art dalam menangani data tabular kompleks yang dihasilkan dari proses feature engineering pada data runtun waktu untuk memprediksi luaran klinis (S et al., 2024; Izonin et al., 2024).

Meskipun demikian, akurasi prediktif yang tinggi (high-fidelity) saja belum men-

cukupi untuk adopsi klinis. Hambatan utama dalam implementasi machine learning di lingkungan berisiko tinggi seperti perawatan kesehatan adalah sifat "black box". Masalah "black box" pada machine learning di bidang kesehatan merujuk pada kurangnya transparansi dan interpretabilitas dari model-model kompleks seperti deep learning, sehingga sulit bagi klinisi dan pasien untuk memahami alasan di balik prediksi atau rekomendasi yang dihasilkan (Poon & Sung, 2021; Rudin, 2018). Model-model ini sering kali kurang memiliki transparansi internal karena meskipun mampu menghasilkan prediksi (output) yang akurat, model tersebut tidak dapat memberikan justifikasi yang mudah dipahami manusia atas keputusan yang diambil (Elshaw et al., 2019). Kurangnya transparansi internal pada model dapat menghambat kepercayaan dan akuntabilitas, sehingga penting untuk mengembangkan sistem yang memungkinkan penelusuran dan verifikasi alasan di balik setiap rekomendasi atau peringatan otomatis (Visco et al., 2023).

Untuk mengatasi kesenjangan antara akurasi dan interpretabilitas ini, disiplin Explainable AI (XAI) menjadi sangat krusial. Metode XAI, khususnya metode atribusi post-hoc seperti SHAP (SHapley Additive exPlanations), menawarkan solusi yang kuat. SHAP, yang didasarkan pada teori permainan kooperatif, mampu mengkalikulasi kontribusi spesifik dari setiap fitur masukan terhadap deviasi prediksi model dari nilai dasarnya (Khan et al., 2024; Ali et al., 2023). Pendekatan ini secara efektif memberikan penjelasan yang terukur mengenai alasan di balik terbentuknya suatu prediksi tertentu (Nohara et al., 2021).

Oleh karena itu, penelitian ini mengusulkan pengembangan Digital Twin berbasis data sebagai purwarupa sistem pendukung keputusan klinis (CDSS) yang dirancang untuk memadukan akurasi dan transparansi. Konsep ini merujuk pada model yang digerakkan oleh algoritma machine learning seperti Random Forest dan XGBoost, bukan pada simulasi fisiologis mekanistik yang bersifat menyeluruh. Melalui integrasi antara model prediktif yang andal dan metode penjelasan SHAP, penelitian ini bertujuan menjembatani kesenjangan dalam adopsi sistem cerdas dengan menghadirkan alat yang mampu memberikan peringatan tentang apa yang diprediksi sekaligus menjelaskan alasan di balik prediksi tersebut.

I.2 Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah dalam penelitian ini adalah:

1. Bagaimana merancang proses feature engineering untuk mengubah data runtun waktu (time-series) berfrekuensi tinggi dari MIMIC-IV menjadi set fitur

tabular yang relevan untuk memprediksi krisis hipertensi?

2. Bagaimana mengembangkan dan mengevaluasi model machine learning (XGBoost/RF) untuk mencapai akurasi prediksi risiko krisis hipertensi jangka pendek yang optimal?
3. Bagaimana mengimplementasikan metode SHAP untuk menganalisis model yang telah dilatih dan memberikan penjelasan yang dapat ditafsirkan (interpretable) untuk setiap prediksi risiko individu?
4. Bagaimana Purwarupa Digital Twin Hipertensi berbasis machine learning dapat dirancang untuk menampilkan hasil prediksi dan rasionalisasi SHAP secara user-friendly bagi pengguna?

I.3 Tujuan

Tujuan utama pelaksanaan Tugas Akhir ini adalah:

1. Mengekstraksi kohort pasien yang relevan dan membangun pipeline feature engineering untuk memproses data runtun waktu dari MIMIC-IV.
2. Mengembangkan dan memvalidasi model prediktif (XGBoost/RF) yang akurat untuk memberikan peringatan dini (early warning) krisis hipertensi.
3. Mengaplikasikan SHAP untuk mengidentifikasi faktor-faktor klinis utama/fitur yang paling berkontribusi terhadap prediksi risiko tinggi, sehingga memberikan transparansi pada keluaran model.
4. Merancang dan membangun Purwarupa Digital Twin sederhana dan interaktif untuk mendemonstrasikan hasil prediksi dan rasionalisasi SHAP secara user-friendly bagi pengguna.

I.4 Batasan Masalah

Batasan-batasan masalah yang diambil dalam pelaksanaan tugas akhir ini adalah sebagai berikut:

1. Penelitian ini berfokus pada perancangan, pengembangan, dan evaluasi purwarupa dalam lingkungan simulasi. Penelitian ini tidak mencakup implementasi klinis di rumah sakit atau uji coba prospektif pada pasien nyata.
2. Sumber data difokuskan namun tidak terbatas pada dataset publik anonim MIMIC-IV. Kohort pasien berasal dari lingkungan ICU, sehingga generalisasi model ke populasi hipertensi umum (rawat jalan) memerlukan validasi lebih lanjut.
3. Model Digital Twin yang dimaksud penulis merujuk pada model prediktif berbasis data (XGBoost/RF), bukan model simulasi fisiologis mekanistik yang

komprehensif.

4. Eksplorasi model terbatas pada algoritma Machine Learning. Metode Explainable AI yang diimplementasikan adalah SHAP (SHapley Additive Explanations) namun kajian lebih dalam untuk validasi tetap diperlukan.
5. Keluaran sistem adalah skor risiko dan penjelasan fitur (SHAP values), yang berfungsi sebagai pendukung keputusan, bukan sebagai diagnosis medis otomatis.

I.5 Metodologi

Penelitian ini menggunakan pendekatan kuantitatif dengan desain studi berupa pemodelan komputasi dan analisis data sekunder. Alur penelitian (research workflow) dirancang secara sistematis dalam beberapa tahapan utama yang saling berurutan untuk mencapai tujuan yang telah ditetapkan. Tahapan-tahapan tersebut akan dielaborasi secara rinci dalam Bab 3, namun secara garis besar adalah sebagai berikut:

1. **Studi Literatur dan Akuisisi Data** Tahap awal penelitian mencakup studi literatur mendalam mengenai hipertensi, krisis hipertensi, arsitektur Digital Twin di bidang kesehatan, model machine learning (khususnya XGBoost/RF), dan implementasi Explainable AI (XAI) menggunakan SHAP. Secara paralel, dilakukan proses akuisisi data dengan mengakses dan mengunduh dataset anonim MIMIC-IV dari PhysioNet, setelah memenuhi persyaratan etika data.
2. **Pra-Pemrosesan dan Ekstraksi Kohort** Data mentah MIMIC-IV yang berukuran sangat besar akan diproses. Tahap ini berfokus pada:
 - Ekstraksi Kohort: Mendefinisikan kriteria inklusi dan eksklusi (misalnya, pasien dewasa dengan diagnosis hipertensi, ketersediaan data vital sign minimal 24 jam) untuk menyaring dan memilih populasi studi yang relevan.
 - Pembersihan Data: Menangani data yang hilang (missing values), data yang tidak konsisten, dan normalisasi data.
3. **Feature Engineering** Ini adalah tahap krusial untuk mengubah data runtun waktu (time-series) berfrekuensi tinggi menjadi format data tabular yang statis dan siap digunakan oleh model ML. Proses ini mencakup ekstraksi fitur-fitur yang relevan secara klinis, seperti fitur agregat (misal, rata-rata, min, maks TD dalam 3 jam), fitur tren (misal, slope atau kemiringan grafik TD dalam 1 jam terakhir), dan fitur temporal (misal, waktu sejak pemberian obat anti-hipertensi terakhir).
4. **Pengembangan Model Prediktif** Pada tahap ini, data tabular yang telah bersih dibagi menjadi data latih (training set) dan data uji (testing set). Model

ensemble (diprioritaskan XGBoost atau Random Forest) akan dilatih menggunakan data latih untuk memprediksi target outcome yang telah didefinisikan (misalnya, probabilitas terjadinya krisis hipertensi dalam N jam ke depan).

5. **Evaluasi Kinerja dan Analisis Penjelasan (XAI)** Model yang telah dilatih akan dievaluasi kinerjanya menggunakan data uji dengan metrik standar seperti Area Under the Receiver Operating Characteristic Curve (AUC-ROC), Akurasi, Presisi, dan Recall. Setelah model divalidasi, metode SHAP akan diaplikasikan untuk:
 - Secara Global: Mengidentifikasi fitur apa yang paling berpengaruh secara umum terhadap prediksi model (SHAP Summary Plot).
 - Secara Lokal: Menganalisis prediksi individu untuk memahami kontribusi spesifik setiap fitur pada kasus pasien tertentu (SHAP Force Plot).
6. **Perancangan Purwarupa dan Visualisasi** Sebagai tahap akhir, sebuah purwarupa (prototype) dashboard visualisasi sederhana akan dikembangkan (misalnya menggunakan Streamlit atau Dash). Dashboard ini akan mensimulasikan fungsionalitas Digital Twin dengan menampilkan prediksi risiko (output model) beserta penjelasannya (output SHAP) secara interpretable.

BAB II

STUDI LITERATUR

II.1 Krisis Hipertensi

Krisis Hipertensi merupakan suatu kondisi medis serius yang ditandai oleh peningkatan tekanan darah (TD) akut yang parah. Kondisi ini umumnya didefinisikan ketika Tekanan Darah Sistolik (TDS) melebihi 180 mmHg atau Tekanan Darah Diastolik (TDD) melebihi 120 mmHg (StatPearls 2025; Mayo Clinic 2022). Identifikasi dan tatalaksana segera sangat penting untuk mencegah kerusakan organ permanen atau risiko kematian (StatPearls 2025). Krisis ini diklasifikasikan berdasarkan keberadaan kerusakan organ target akut yang dimediasi oleh hipertensi atau HMOD, membaginya menjadi Hipertensi Urgensi dan Hipertensi Emergensi (Cleveland Clinic 2024; StatPearls 2025).

II.1.1 Hipertensi Urgensi (Hypertensive Urgency)

Hipertensi Urgensi ditandai dengan peningkatan TD yang parah yaitu TD sistolik melebihi 180 mmHg dan TD diastolik melebihi 120 mmHg tanpa adanya tanda-tanda kerusakan organ target akut yang baru atau progresif (StatPearls 2023). Gejala yang mungkin dialami pasien dalam kondisi urgensi cenderung non-spesifik, mencakup sakit kepala berkepanjangan, mimisan, pusing, atau kegelisahan (MSF 2025; Cleveland Clinic 2024). Karena ketiadaan kerusakan organ akut, tatalaksana diarahkan pada penurunan tekanan darah secara bertahap dalam kurun waktu 24 hingga 48 jam, umumnya menggunakan medikasi oral (StatPearls 2025).

II.1.2 Hipertensi Emergensi (Hypertensive Emergency)

Hipertensi Emergensi adalah kondisi yang mengancam jiwa dan memerlukan intervensi segera (BMJ Best Practice 2024). Kondisi ini dicirikan oleh TD yang sangat tinggi yaitu TD sistolik melebihi 180 mmHg dan TD diastolik melebihi 120 mmHg

yang disertai bukti kerusakan organ target akut. Kerusakan organ yang dapat terjadi meliputi sistem saraf, yang dapat memunculkan perubahan status mental, kebingungan, atau perubahan penglihatan. Selain itu, kerusakan juga dapat terjadi pada jantung, memicu gagal jantung atau infark miokard, ginjal yang menyebabkan gagal ginjal akut, serta pembuluh darah besar, misalnya diseksi aorta atau aneurisma (StatPearls 2024; AHA 2025).

II.1.3 Faktor Pemicu Utama

Salah satu penyebab paling umum krisis hipertensi pada pasien dengan riwayat hipertensi kronis adalah *ketidakpatuhan pasien*, yang berarti kegagalan mengikuti jadwal dan dosis pengobatan antihipertensi yang diresepkan (MDPI 2022; StatPearls 2025). Faktor pemicu lain meliputi kondisi seperti preeklampsia atau eklampsia dalam kehamilan, adanya penyakit ginjal, serta penggunaan obat-obatan yang dapat meningkatkan TD, misalnya obat antiinflamasi nonsteroid atau stimulan seperti kokain (MSF 2025; StatPearls 2024).

II.1.4 Prosedur Diagnostik

Evaluasi pasien dengan kecurigaan krisis hipertensi harus dilakukan dengan cepat untuk menentukan keberadaan kerusakan organ target (StatPearls 2024). Rangkaian tes diagnostik yang direkomendasikan mencakup:

1. Pemeriksaan laboratorium, seperti Hitung Darah Lengkap, Panel Metabolik Lengkap untuk menilai fungsi ginjal, dan enzim jantung seperti Troponin serta BNP untuk menilai cedera miokard (BMJ Best Practice 2024).
2. Pemeriksaan urin untuk mengevaluasi fungsi ginjal (BMJ Best Practice 2024).
3. Pemeriksaan pencitraan dan jantung: EKG dilakukan untuk menilai irama jantung, sedangkan Rontgen Dada dapat mendeteksi gagal jantung kongestif (BMJ Best Practice 2024).
4. Jika ada gejala neurologis seperti nyeri kepala hebat, CT scan kepala diindikasikan untuk menyingkirkan perdarahan intrakranial atau stroke (StatPearls 2024).

II.1.5 Prinsip Tatalaksana Hipertensi Emergensi

Tatalaksana pada Hipertensi Emergensi membutuhkan rawat inap dan pengawasan intensif, seringkali di ICU, serta pemberian obat antihipertensi secara intravena (BMJ Best Practice 2024). Tujuan utama terapi adalah mengurangi tekanan darah secara bertahap dan terkontrol untuk mencegah hipoperfusi pada organ yang telah

terbiasa dengan TD tinggi kronis (ACCP 2018). Penurunan TD yang terlalu cepat harus dihindari karena berisiko memicu iskemia serebral, koroner, atau ginjal (BMJ Best Practice 2024). Untuk target penurunan umum, pedoman klinis merekomendasikan penurunan Tekanan Arteri Rerata atau MAP tidak lebih dari 20% hingga 25% dalam jam pertama (StatPearls 2024; BMJ Best Practice 2024). Setelahnya, TD diturunkan secara bertahap menuju 160/100-110 mmHg dalam waktu 2 hingga 6 jam berikutnya (BMJ Best Practice 2024).

II.2 Konsep Digital Twin dalam Kesehatan

Konsep Digital Twin, yang berasal dari industri manufaktur, merujuk pada representasi virtual atau kembaran digital dari sebuah objek, proses, atau sistem fisik. Kembaran digital ini diperbarui secara dinamis menggunakan data real-time dari mitra fisiknya, memungkinkannya untuk melakukan pemantauan, analisis, dan simulasi (Emmert-Streib & Yli-Harja, 2024).

Dalam konteks kesehatan, Digital Twin berevolusi menjadi model virtual personal dari pasien. Model ini mengintegrasikan data pasien multi-modal, termasuk data fisiologis, demografis, dan riwayat klinis, untuk mensimulasikan status kesehatan individu.

Terdapat dua pendekatan utama dalam membangun Digital Twin kesehatan:

1. Model mekanistik, yang mencoba mensimulasikan fisiologi manusia secara komprehensif menggunakan persamaan diferensial dan prinsip-prinsip biologi.
2. Model data-driven atau berbasis data, yang menjadi fokus penelitian ini.

Penelitian ini mendefinisikan "*Digital Twin Sederhana*" sebagai sebuah purwarupa sistem interaktif yang intinya ditenagai oleh model machine learning (Laubenbacher et al., 2022). Model ini tidak mensimulasikan seluruh biologi, melainkan belajar dari pola data historis untuk memprediksi *outcome* spesifik dan memungkinkan simulasi intervensi "*what-if*" berbasis data. Penerapan konsep ini terbukti relevan untuk manajemen penyakit kronis, di mana model Digital Twin telah dieksplorasi untuk memprediksi kadar glukosa pada pasien diabetes atau memantau risiko gagal jantung, menunjukkan potensinya dalam menyediakan peringatan dini yang dipersonalisasi.

II.3 Landasan Pemodelan Prediktif Klinis

Pengembangan model data-driven ini mengikuti alur kerja penemuan pengetahuan yang sistematis. Alur kerja standar dalam data science, sering disebut sebagai *Knowledge Discovery in Databases (KDD)*, menyediakan kerangka kerja metodologis yang formal. Proses KDD terdiri dari beberapa tahapan inti yang iteratif: Seleksi Data, Pra-pemrosesan, Transformasi, Data Mining (Pemodelan), dan Evaluasi atau Interpretasi (Fayyad et al., 1996). Setiap tahap memiliki peran krusial dalam membangun model yang valid dan andal.

II.3.1 Sumber Data dan Pra-pemrosesan

Penelitian ini memanfaatkan dataset *MIMIC-IV* (Medical Information Mart for Intensive Care) sebagai sumber data. MIMIC-IV adalah *database* publik berskala besar yang berisi data rekam medis elektronik de-identifikasi dari pasien yang dirawat di unit perawatan intensif (ICU) di Beth Israel Deaconess Medical Center (Johnson et al., 2023). Relevansi *dataset* ini terletak pada ketersediaan data vital sign beresolusi tinggi, yang dicatat dalam tabel *chartevents*. Data ini memungkinkan pelacakan fluktuasi tekanan darah dari jam ke jam, yang merupakan prasyarat mutlak untuk membangun model peringatan dini proaktif.

II.3.2 Feature Engineering

Tahap Transformasi, atau *Feature Engineering*, adalah langkah fundamental dalam alur kerja ini. Model *machine learning* klasik seperti XGBoost tidak dapat memproses data runtun waktu (*time-series*) mentah secara langsung; mereka memerlukan input dalam bentuk tabel fitur yang statis. Oleh karena itu, teknik *feature engineering* diperlukan untuk mengekstrak informasi prediktif dari data runtun waktu (Shickel et al., 2018). Ini melibatkan penerapan *sliding window* (jendela geser) pada data historis pasien (misalnya, data 12 jam terakhir) untuk mengkalkulasi variabel atau fitur baru. Fitur-fitur ini dapat berupa:

- statistik agregat seperti "mean_TD_3jam" (rata-rata tekanan darah 3 jam terakhir),
- fitur tren seperti "slope_TD_1jam" (kemiringan grafik tekanan darah 1 jam terakhir), atau
- fitur temporal seperti "waktu_sejak_obat_terakhir".

Kualitas dari fitur-fitur inilah yang akan menentukan kinerja dari model prediktif.

II.4 Model Machine Learning dan Evaluasi

Inti dari proses **data mining** adalah pemilihan dan penerapan algoritma **machine learning**. Penelitian ini berfokus pada *model ensemble*, yang dikenal karena kinerjanya yang tinggi. Model **ensemble** menggabungkan prediksi dari beberapa model yang lebih lemah untuk menghasilkan satu prediksi akhir yang kuat. Dua metode **ensemble** yang paling populer adalah *Random Forest* dan *XGBoost* (**Extreme Gradient Boosting**) (Chen & Guestrin, 2016). XGBoost seringkali menunjukkan kinerja superior pada data tabular terstruktur seperti yang akan dihasilkan dari proses **feature engineering**. Keunggulannya terletak pada kemampuannya menangani data yang hilang (*missing values*) secara internal dan regularisasi yang kuat untuk mencegah **overfitting**.

II.4.1 Metrik Evaluasi

Karena target luaran adalah prediksi risiko krisis hipertensi (masalah klasifikasi biner), evaluasi kinerja tidak bisa hanya bergantung pada metrik akurasi, terutama pada data medis yang seringkali tidak seimbang (*imbalanced*). Metrik evaluasi yang lebih relevan akan digunakan, seperti:

- *Precision* (kemampuan model untuk tidak salah memberi alarm palsu).
- *Recall* (kemampuan model untuk menemukan semua kasus krisis yang sebenarnya).
- *F1-Score*.

Secara khusus, *Area Under the Receiver Operating Characteristic Curve (AUC-ROC)* akan digunakan sebagai metrik evaluasi utama. AUC-ROC mengukur kemampuan diskriminatif model secara keseluruhan, yaitu seberapa baik model dapat membedakan antara pasien yang akan mengalami krisis dan yang tidak, terlepas dari ambang batas prediksi yang dipilih (Jeni et al., 2013).

—

II.5 Explainable AI (XAI) dalam Medis

Masalah fundamental dengan model **ensemble** yang kuat seperti XGBoost adalah sifatnya sebagai *"kotak hitam"* (*black box*). Model ini dapat menghasilkan prediksi yang sangat akurat, namun proses pengambilan keputusannya sangat kompleks dan tidak dapat dipahami secara intuitif oleh manusia. Dalam domain berisiko tinggi seperti kedokteran, akurasi saja tidak cukup (Ahmad et al., 2021). Kebutuhan akan kepercayaan (*trust*), transparansi, dan akuntabilitas (*accountability*) menjadikan

Explainable AI (XAI) sebagai komponen wajib.

Implementasi *SHAP* akan menghasilkan dua jenis penjelasan utama yang krusial untuk purwarupa Digital Twin:

1. *Interpretabilitas Global* (SHAP Summary Plot): Menunjukkan fitur apa saja, seperti "slope_TD_1jam", yang memiliki dampak paling besar secara keseluruhan pada prediksi model.
2. *Interpretabilitas Lokal* (SHAP Force Plot atau Waterfall Plot): Menjelaskan secara rinci mengapa satu prediksi spesifik dibuat untuk satu pasien individu pada satu waktu tertentu.

Kemampuan untuk memberikan alasan di balik setiap peringatan inilah yang mengubah model prediktif menjadi sistem pendukung keputusan yang dapat dipercaya.

II.6 Penelitian Terkait dan Posisi Penelitian

Penelitian ini berada di persimpangan tiga domain riset aktif: pemodelan prediktif di ICU, *ensemble learning*, dan XAI. Tinjauan pustaka menunjukkan bahwa *dataset* MIMIC-IV telah banyak digunakan untuk pemodelan prediktif, tetapi fokusnya seringkali pada luaran lain seperti prediksi sepsis, mortalitas di ICU, atau kejadian hipotensi (Rahman et al., 2021). Studi-studi ini memvalidasi penggunaan MIMIC-IV untuk pemodelan runtun waktu, namun menyisakan celah pada prediksi spesifik krisis hipertensi.

Kombinasi XGBoost dan SHAP telah muncul sebagai *state-of-the-art* untuk membangun model klinis yang interpretable, terbukti dalam memprediksi luaran kardiovaskular seperti mortalitas pasca-infark miokard (Jia et al., 2023).

Kebaruan (*novelty*) dan posisi penelitian ini terletak pada sintesis unik dari ketiga domain tersebut:


- *Fokus Spesifik*: Fokus secara spesifik pada *prediksi risiko krisis hipertensi* di lingkungan ICU, sebuah masalah kritis yang sering terabaikan.
- *Horizon Waktu*: Mengembangkan dan membandingkan model pada beberapa horizon waktu (misalnya, prediksi jangka pendek N -jam vs. jangka menengah M -jam), yang akan memberikan wawasan klinis lebih dalam.
- *Kontribusi Utama*: Pengembangan purwarupa Digital Twin fungsional yang menyajikan peringatan dini yang *dapat dijelaskan dan ditindaklanjuti* (*explainable and actionable insights*) secara *real-time* (tersimulasi) menggunakan

SHAP.

BAB III

ANALISIS MASALAH

III.1 Analisis Kondisi Saat Ini



Gambar III.1 Alur proses 'As-Is' manajemen klinis hipertensi

Proses manajemen klinis untuk pasien hipertensi saat ini beroperasi pada paradigma yang fundamentalnya bersifat reaktif. Alur kerja konvensional ini, seperti yang telah dimodelkan, bergantung pada intervensi yang baru dilakukan setelah diagnosis ditegakkan atau setelah terjadi fluktuasi tekanan darah (TD) yang signifikan. Kelemahan utama dari pendekatan ini adalah kegagalannya dalam mengantisipasi dan mencegah episode akut yang paling berbahaya, yaitu krisis hipertensi. Krisis hipertensi didefinisikan sebagai kondisi darurat medis di mana tekanan darah melonjak melebihi 180/120 mmHg. Kondisi ini secara langsung berpotensi menyebabkan kerusakan pada organ target, seperti stroke atau gagal jantung, sehingga menjadikannya tantangan serius bagi kesehatan masyarakat. Dengan demikian, alur kerja yang hanya menunggu terjadinya krisis adalah model yang secara inheren berisiko tinggi

dan tidak memadai.

Urgensi untuk mengatasi masalah ini diperkuat oleh definisi klinis dari krisis hipertensi itu sendiri. Kondisi ini diklasifikasikan sebagai Hypertensive Emergency (Hipertensi Emergensi) ketika lonjakan TD yang parah (melebihi 180/120 mmHg) disertai dengan bukti adanya kerusakan organ target akut. Kerusakan ini dapat bermanifestasi secara cepat dan parah, meliputi perubahan status mental, infark miokard, gagal ginjal akut, atau diseksi aorta. Dalam paradigma "As-Is", alarm atau eskalasi ke dokter baru terjadi setelah kondisi yang mengancam jiwa ini dimulai, sehingga waktu penanganan yang krusial telah hilang. Identifikasi dan tatalaksana yang segera sangat penting untuk mencegah kerusakan organ permanen atau risiko kematian. Oleh karena itu, jelas bahwa sistem yang hanya "bereaksi" terhadap krisis yang sudah terjadi secara fundamental gagal dalam misi preventif.

Kebutuhan untuk bertransisi menuju manajemen proaktif kini menjadi mungkin berkat kemajuan dalam pengumpulan data dan machine learning. Ketersediaan dataset publik beresolusi tinggi, seperti MIMIC-IV, menyediakan rekaman data longitudinal yang rinci, termasuk data runtun waktu (time-series) dari tanda-tanda vital seperti nilai TD per jam. Data historis yang kaya ini merupakan prasyarat mutlak yang memungkinkan pelatihan model prediktif untuk memantau fluktuasi tekanan darah dari jam ke jam. Dengan memanfaatkan data ini, sebuah sistem dapat dikembangkan untuk memberikan peringatan dini. Tujuan utamanya adalah untuk memprediksi probabilitas terjadinya krisis hipertensi sebelum ambang batas 180/120 mmHg terlampaui, sehingga memungkinkan intervensi preventif.

Meskipun model machine learning (ML) seperti ensemble (Random Forest atau XGBoost) telah menunjukkan kinerja state-of-the-art dalam menangani data tabular kompleks, akurasi prediktif yang tinggi (high-fidelity) saja belum mencukupi untuk adopsi klinis. Hambatan utama dalam implementasi machine learning di lingkungan berisiko tinggi seperti perawatan kesehatan adalah sifat alaminya sebagai "kotak hitam" (black box). Masalah "black box" ini merujuk pada kurangnya transparansi dan interpretabilitas dari model-model kompleks. Meskipun model tersebut mampu menghasilkan prediksi (keluaran) yang sangat akurat, model tersebut tidak dapat memberikan justifikasi yang mudah dipahami manusia atas keputusan yang diambil. Opasitas ini menjadi masalah kritis di bidang kedokteran, di mana setiap rekomendasi otomatis harus dapat diverifikasi dan dipertanggungjawabkan.

Konsekuensi langsung dari masalah "black box" adalah terhambatnya kepercayaan dan akuntabilitas dari pengguna akhir, yaitu para klinisi. Seorang dokter tidak da-

pat memercayai atau menindaklanjuti sebuah peringatan "Risiko Krisis 85%" jika sistem tidak dapat memberikan justifikasi yang masuk akal dan dapat ditindaklanjuti secara klinis. Kurangnya transparansi internal ini menciptakan keraguan, karena pengguna tidak dapat memverifikasi alasan di balik peringatan tersebut. Dalam domain di mana keputusan dapat berarti antara hidup dan mati, sistem yang tidak dapat dipertanggungjawabkan tidak akan pernah diadopsi sepenuhnya, tidak peduli seberapa akurat prediksinya. Kesenjangan kepercayaan ini adalah penghalang adopsi yang sama seriusnya dengan masalah paradigma reaktif itu sendiri.

Untuk menjembatani kesenjangan antara akurasi prediktif dan adopsi klinis, disiplin AI yang dapat dijelaskan (Explainable AI atau XAI) menjadi komponen yang krusial dan wajib ada. XAI menawarkan solusi untuk "membuka" kotak hitam dan memberikan transparansi yang dibutuhkan. Metode atribusi post-hoc yang kuat seperti SHAP (SHapley Additive exPlanations) secara khusus dirancang untuk mengatasi masalah ini. SHAP, yang didasarkan pada teori permainan kooperatif, mampu mengkalkulasi kontribusi spesifik dari setiap fitur (misalnya, 'usia', 'TD 3 jam terakhir') terhadap deviasi prediksi model dari nilai dasarnya. Metode ini secara efektif memberikan penjelasan yang terukur (baik secara global maupun lokal per individu) mengenai alasan di balik terbentuknya suatu prediksi risiko. Kemampuan untuk menyediakan rasionalisasi inilah yang akan mengubah model ML dari sekadar alat prediksi menjadi sistem pendukung keputusan yang dapat dipercaya.

III.1.1 Analisis Kesenjangan

Dilakukan analisis kesenjangan berikut ini untuk memetakan secara terstruktur kondisi saat ini (As-Is) dengan kondisi ideal (To-Be) yang diharapkan dari solusi yang diusulkan. Pemetaan ini merangkum permasalahan inti yang dijabarkan dalam Tabel III.1 ini.

Tabel III.1 Analisis Kesenjangan (Gap Analysis)

Domain Masalah	Kondisi Saat ini (As-Is)	Kesenjangan (Gap)	Kondisi Ideal (To-Be)
Manajemen Klinis (Proses)	Paradigma intervensi bersifat reaktif. Tindakan medis darurat baru diambil setelah pasien mengalami krisis hipertensi (TD > 180/120 mmHg).	Keterlambatan intervensi kritis dan risiko kerusakan organ target (stroke, gagal jantung) yang tidak terantisipasi karena kegagalan mendeteksi risiko lebih awal.	Paradigma manajemen bersifat proaktif. Klinisi mendapatkan peringatan dini yang akurat untuk mengantisipasi risiko krisis sebelum terjadi.
Adopsi Teknologi	Model machine learning (ML) yang akurat bersifat "black box". Klinisi tidak dapat memahami atau memverifikasi alasan di balik sebuah peringatan risiko.	Hambatan adopsi dan kurangnya kepercayaan (trust) pada sistem cerdas. Sistem tidak akuntabel sehingga sulit diimplementasikan di lingkungan berisiko tinggi.	Model ML bersifat transparan dan dapat dijelaskan. Sistem mampu memberikan justifikasi (via SHAP) untuk setiap prediksi risiko individu, sehingga membangun kepercayaan klinis.
Pemanfaatan Data (Sistem)	Data runtun waktu (time-series) klinis beresolusi tinggi (dari MIMIC-IV) ada, namun belum 16 dimanfaatkan secara optimal untuk prediksi	Peluang yang terlewatkan. Data historis yang kaya hanya digunakan untuk analisis retrospektif, bukan untuk memprediksi dan mencegah outcome buruk	Data time-series diproses melalui alur kerja (pipeline) rekayasa fitur untuk melatih model ML yang mampu mengubah data historis menja-

Di sini diketahui bahwa masalah yang dihadapi bersifat multifaset, mencakup aspek proses klinis (paradigma reaktif) dan aspek teknologi (masalah "black box"). Kesenjangan ini menunjukkan kebutuhan mendesak akan sebuah solusi cerdas yang tidak hanya menyajikan prediksi outcome, tetapi juga mampu menyajikan rasionalisasi dari prediksi tersebut untuk membangun kepercayaan. Untuk dapat merancang solusi yang efektif dalam menutup kesenjangan ini, langkah selanjutnya adalah menerjemahkan kebutuhan tersebut ke dalam spesifikasi fungsional dan non-fungsional yang terukur.

III.2 Analisis Kebutuhan

Berdasarkan analisis kesenjangan yang telah dipaparkan sebelumnya, langkah selanjutnya adalah menerjemahkan kebutuhan solusi menjadi serangkaian spesifikasi yang terukur. Tahap ini krusial untuk memastikan bahwa sistem yang akan dikembangkan, yaitu purwarupa "Digital Twin Sederhana", secara langsung menjawab dua masalah fundamental yang telah diidentifikasi. Spesifikasi ini akan dibagi menjadi tiga kategori utama: identifikasi masalah spesifik dariacamata pengguna, kebutuhan fungsional (apa yang harus dilakukan sistem), dan kebutuhan non-fungsional (kriteria kualitas sistem). Proses pendefinisian kebutuhan ini akan menjadi cetak biru (blueprint) yang memandu seluruh alur kerja penelitian, mulai dari akuisisi data hingga perancangan prototipe.

III.2.1 Identifikasi Masalah Pengguna

Pengguna utama dari sistem "To-Be" yang diusulkan adalah Klinisi di lingkungan perawatan intensif, yang mencakup Dokter (sebagai pengambil keputusan) dan Perawat (sebagai pelaksana monitor dan intervensi). Berdasarkan analisis kondisi "As-Is" (3.1), kedua pengguna ini menghadapi dua masalah spesifik yang saling terkait. Masalah pertama adalah beban kognitif dan risiko keterlambatan intervensi akibat paradigma reaktif. Perawat ICU dihadapkan pada beban kerja pemantauan manual yang tinggi, di mana mereka harus mengamati tanda vital pasien secara periodik (misal, per jam). Masalahnya, krisis hipertensi dapat berkembang cepat di antara interval pengecekan, sehingga memunculkan risiko kesalahan manusiawi (human error) atau deteksi yang terlambat. Bagi Dokter, masalahnya adalah mereka baru menerima eskalasi darurat setelah pasien berada dalam kondisi krisis, sehingga kehilangan waktu emas untuk melakukan pencegahan.

Masalah kedua adalah ketidakpercayaan dan keraguan adopsi akibat sistem "kotak hitam". Ketika sebuah solusi teknologi (seperti model ML) ditawarkan untuk

mengatasi masalah pertama, pengguna klinis dihadapkan pada masalah baru: ketidakmampuan untuk memvalidasi atau memahami mengapa sebuah peringatan risiko muncul. Bagi Dokter, masalah ini sangat fundamental karena mereka tidak dapat menindaklanjuti (misalnya, memberikan obat preventif) sebuah peringatan yang tidak dapat dijelaskan. Hal ini menciptakan masalah turunan berupa "keraguan dalam pengambilan keputusan" (hesitancy to act) dan masalah "akuntabilitas", di mana klinisi tidak dapat bertanggung jawab atas keputusan yang didasarkan pada alat yang buram (opaque). Oleh karena itu, masalah pengguna yang teridentifikasi bukan hanya "butuh prediksi", tetapi "butuh prediksi yang dapat dipercaya dan dijelaskan."

III.2.2 Kebutuhan Fungsional

Kebutuhan fungsional (Functional Requirements) adalah pernyataan spesifik mengenai fungsionalitas atau layanan inti yang harus disediakan sistem untuk memecahkan masalah pengguna yang teridentifikasi di 3.2.1. Kebutuhan ini diturunkan secara langsung dari alur kerja penelitian yang diuraikan dalam Bab 1.5 dan bertujuan untuk menutup kesenjangan teknis yang ada. Setiap fungsi harus dapat diimplementasikan dan diuji untuk memvalidasi bahwa sistem mampu mengeksekusi tugas-tugas yang diperlukan untuk mencapai tujuan proaktif dan dapat dijelaskan. Fungsi-fungsi ini mencakup seluruh siklus hidup data, mulai dari pemrosesan data mentah, transformasi fitur, pemodelan, hingga visualisasi hasil akhir. Kebutuhan fungsional dijabarkan sebagai berikut:

Tabel III.2 Kebutuhan Fungsional

ID	Kebutuhan Fungsional	Deskripsi
F-01	Manajemen & Ekstraksi Data	Sistem terbukti mampu memuat file .csv dari dataset MIMIC-IV Demo (100 pasien). Sistem harus mampu memvalidasi dan mengekstrak kohort pasien krisis (27 pasien unik yang teridentifikasi).
F-02	Rekayasa Fitur (Feature Engineering)	Sistem mampu menghasilkan satu tabel fitur (X) statis dan satu tabel target (Y) biner (1 = Krisis, 0 = Aman). Tabel fitur (X) wajib mencakup fitur statis (usia, gender) dan fitur agregat/tren (misal: rata-rata, slope TD).
F-03	Pemodelan Prediktif	
F-04	Implementasi Interpretabilitas (XAI)	Sistem mampu menghasilkan visualisasi SHAP Summary Plot untuk penjelasan global. Sistem juga wajib mampu menghasilkan visualisasi SHAP Force Plot atau Waterfall Plot untuk setiap prediksi individu (penjelasan lokal).
F-05	Visualisasi Prototipe CDSS (Dashboard)	Sistem (dibangun dengan Streamlit) mampu menampilkan secara bersamaan: (1) Skor prediksi risiko (dari F-3) dan (2) Visualisasi penjelasan SHAP (dari F-4) dalam satu antarmuka dashboard interaktif.

III.2.3 Kebutuhan Nonfungsional

Kebutuhan non-fungsional (Non-Functional Requirements) mendefinisikan kriteria kualitas, batasan operasional, dan atribut sistem yang tidak terkait langsung dengan fungsi spesifik. Dalam konteks penelitian medis ini, kebutuhan non-fungsional sama pentingnya dengan kebutuhan fungsional karena menentukan validitas, kepercayaan, dan reliabilitas dari solusi yang diusulkan. Kebutuhan ini menetapkan standar "seberapa baik" sistem harus bekerja, bukan hanya "apa" yang harus dilakukannya. Berikut adalah kebutuhan non-fungsional utama untuk sistem ini:

Tabel III.3 Kebutuhan Nonfungsional

ID	Kebutuhan Non-Fungsional	Deskripsi (Kriteria Kualitas yang Terukur)
NFR-01	Transparansi	Sistem harus 100% dapat dijelaskan. Setiap prediksi risiko yang dihasilkan (F-3) wajib disertai dengan visualisasi penjelasan SHAP (F-4) yang menunjukkan kontribusi fitur-fitur pendorong risiko.
NFR-02	Kinerja Prediktif	Kinerja model pada test set wajib dievaluasi menggunakan metrik utama AUC-ROC. Kinerja juga harus dilaporkan menggunakan Precision dan Recall, dengan penekanan analisis pada minimalisasi False Negative (pasien krisis yang diprediksi aman).
NFR-03	Kebergunaan (Usability)	Visualisasi SHAP (F-4) pada dashboard (F-5) harus dapat dipahami secara intuitif oleh pengguna non-teknis (klinisi). Faktor pendorong risiko (fitur) harus disajikan dengan jelas, tanpa jargon ilmu data yang kompleks.
NFR-04	Lingkup Prototipe	Sistem beroperasi sebagai purwarupa dalam lingkungan simulasi (offline). Output sistem (skor risiko & SHAP) berfungsi sebagai pendukung keputusan, bukan diagnosis medis otomatis.

III.3 Analisis Pemilihan Solusi

Dalam merancang sistem "Digital Twin Sederhana" untuk prediksi krisis hipertensi, diperlukan analisis terhadap permasalahan dan potensi peluang untuk merumuskan solusi yang paling tepat. Sub-bab ini menyajikan pemetaan masalah dan peluang yang diidentifikasi dari sub-bab 3.1. Setelah itu, akan dipaparkan perbandingan alternatif solusi teknologi yang relevan, yang kemudian akan dievaluasi menggunakan kerangka kerja formal untuk menentukan solusi terpilih.

III.3.1 Alternatif Solusi

Permasalahan yang muncul dalam lingkup penelitian tugas akhir ini perlu dikaji satu per satu agar penulis dapat merumuskan solusi yang relevan. Identifikasi masalah utama yang telah ditemukan (dari sub-bab 3.1) dijabarkan pada Tabel III.4.

Tabel III.4 Pemetaan Masalah

ID	Masalah	Dampak
M01	Paradigma klinis reaktif; intervensi baru dilakukan setelah krisis hipertensi terjadi.	Risiko kerusakan organ target (stroke, gagal jantung) yang tinggi akibat keterlambatan intervensi preventif.
M02	Model machine learning (ML) bersifat "black box" dan tidak transparan bagi klinisi.	Hambatan adopsi dan kurangnya kepercayaan (trust). Klinisi tidak dapat memvalidasi atau menindaklanjuti peringatan yang tidak dapat dijelaskan.
M03	Data klinis (vital sign) bersifat runtun waktu (time-series) dan kompleks.	Sulit melakukan pemrosesan otomatis oleh model ML tabular (seperti XGBoost/RF) tanpa transformasi data terlebih dahulu.

Uraian permasalahan di atas menunjukkan bahwa didapati kebutuhan akan sistem yang dapat beralih ke paradigma proaktif dan menyajikan informasi risiko yang akurat serta dapat dipercaya. Di sisi lain, proyek yang berakar dari permasalahan ini memiliki potensi besar untuk dikembangkan, yang pemetaan peluangnya dijabarkan pada Tabel III.5.

Tabel III.5 Pemetaan Peluang (Proyek Hipertensi)

ID	Pemetaan Masalah	Peluang
P01	M01, M02	Memungkinkan untuk perancangan CDSS proaktif yang mengintegrasikan modul prediksi risiko (mengatasi M01) dan modul XAI (mengatasi M02).
P02	M03	Ketersediaan dataset MIMIC-IV Demo (Data 1/Notulensi) yang dapat digunakan untuk melatih model machine learning.
P03	M03	Teknik Rekayasa Fitur (Feature Engineering) (F-2) memungkinkan ekstraksi fitur tabular yang relevan dari data runtun waktu yang kompleks.
P04	M01	Algoritma machine learning (seperti XGBoost) dari studi literatur terbukti state-of-the-art untuk data tabular klinis (mendukung F-3).
P05	M02	Algoritma XAI (SHAP) dari studi literatur (Data 1/Bab 2) dapat digunakan untuk memberikan transparansi dan membangun kepercayaan (mendukung F-4).

Penulis mengevaluasi berbagai pendekatan teknis yang dapat diadopsi dalam membangun sistem prediksi krisis hipertensi, yang dijabarkan dalam Tabel III.6 di bawah ini.

Tabel III.6 Alternatif Solusi

No.	Solusi	Kelebihan (Pros)	Kekurangan (Cons)
1.	Model Statistik Dapat Diinterpretasi (cth: Regresi Logistik)	Sangat Transparan: Model bersifat "white box" dan inheren dapat dijelaskan. Sederhana: Komputasi ringan dan mudah diimplementasikan.	Kinerja Terbatas: Cenderung memiliki kinerja prediktif yang lebih rendah pada data medis yang non-linear dan kompleks.
2.	Model Deep Learning (cth: LSTM/RNN)	Kinerja Sangat Tinggi: Sangat baik dalam menangkap pola data runtun waktu mentah.	"Black Box" Ekstrem: Sangat sulit diinterpretasikan (gagal memenuhi NF-1). Kompleksitas Tinggi: Membutuhkan komputasi besar dan implementasi yang rumit.
3.	Model Ensemble + XAI (cth: XGBoost + SHAP)	Kinerja Tinggi: Performa state-of-the-art pada data tabular (hasil F-2). Transparan (via XAI): Memenuhi NF-1 dengan menyediakan penjelasan post-hoc (SHAP). Seimbang: Keseimbangan terbaik antara Kinerja (NF-2) dan Transparansi (NF-1).	Memerlukan Rekayasa Fitur (Feature Engineering): Kinerja sangat bergantung pada kualitas fitur yang diekstraksi (F-2).

III.3.2 Analisis Penentuan Solusi

Dalam menentukan pendekatan teknis dalam merancang sistem ini, dilakukan evaluasi menggunakan metode Weighted Scoring Matrix (WSM). WSM adalah sebuah teknik yang mengombinasikan ukuran kualitatif dan kuantitatif dengan cara memberikan skor pada setiap alternatif solusi terhadap serangkaian kriteria yang relev-

an. Metode ini dipilih karena dianggap tidak terlalu kompleks, fleksibel, dan bobotnya dapat disesuaikan berdasarkan aspek sesuai topik model yang akan dikembangkan. Masing-masing parameter penghitungan bobot diperoleh dari kebutuhan non-fungsional (Tabel III.3) yang telah dijabarkan sebelumnya. Bobot ditentukan berdasarkan prioritas penelitian, di mana Kinerja Prediktif (NF-2) dan Transparansi (NF-1) dianggap sebagai prioritas utama. Setiap alternatif solusi diberikan nilai antara 1 hingga 5 (1 = sangat buruk, 5 = sangat baik). Skor akhir diperoleh dari perkalian nilai dengan bobot masing-masing parameter yang dijabarkan pada Tabel III.7.

Tabel III.7 Pemilihan Solusi dengan Weighted Scoring Model (WSM)

Parameter	Bobot	1. Regresi Logistik Skor (1-5)	2. Deep Learning (LSTM) Skor (1-5)	3. Ensemble + SHAP Skor (1-5)
Kinerja Prediktif (NF-2)	0,45	2	5	4
Transparansi (NF-1)	0,45	5	1	4
Kompleksitas Implementasi	0,10	5	1	3
Total Skor	1,00	3.65	2.80	3.90

III.3.3 Solusi Terpilih

Berdasarkan perhitungan skor total pada Tabel III.7, solusi yang akan diadopsi dalam konteks penelitian tugas akhir ini adalah **Alternatif 3: Model Ensemble + XAI (XGBoost + SHAP)** dengan skor akhir tertinggi yaitu 3,90. Model ini dianggap mampu menangani data tabular hasil rekayasa fitur (F-2) dengan keandalan tinggi, sekaligus memenuhi kebutuhan non-fungsional krusial NF-1 (Transparansi). Solusi ini dipilih karena memberikan keseimbangan terbaik antara kinerja prediktif dan interpretabilitas, yang merupakan dua pilar utama untuk mengatasi masalah yang telah diidentifikasi.

BAB IV

DESAIN KONSEP SOLUSI

Ilustrasikan desain konsep solusi dalam bentuk model konseptual dan penjelasan secara ringkas, beserta perbedaannya dengan sistem saat ini. Ilustrasi harus dapat dibandingkan (*before and after*). Karena masih berupa proposal, bab ini hanya berisi gambar desain konsep solusi tersebut dan penjelasan perbandingannya dengan gambar sistem yang ada saat ini (yang tergambar di awal Bab III).

BAB V

RENCANA SELANJUTNYA

Jelaskan secara detail langkah-langkah rencana selanjutnya, hal-hal yang diperlukan atau akan disiapkan, dan risiko dan mitigasinya, yang meliputi:

1. Rencana implementasi, termasuk alat dan bahan yang diperlukan, lingkungan, konfigurasi, biaya, dan sebagainya.
2. Desain pengujian dan evaluasi, misalnya metode verifikasi dan validasi.
3. Analisis risiko dan mitigasi, misalnya tindakan selanjutnya jika ada yang tidak berjalan sesuai rencana.