

Pengembangan Sistem Prediksi Risiko Hipertensi Menggunakan Machine Learning Terinterpretasi (SHAP) dan Chatbot Berbasis LLM-RAG

Proposal Tugas Akhir

Oleh

**Samuel Franciscus Togar Hasurungan
18222131**



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
Desember 2025**

LEMBAR PENGESAHAN

Pengembangan Sistem Prediksi Risiko Hipertensi Menggunakan Machine Learning Terinterpretasi (SHAP) dan Chatbot Berbasis LLM-RAG

Proposal Tugas Akhir

Oleh

**Samuel Franciscus Togar Hasurungan
18222131**

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Proposal Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 2 Desember 2025

Pembimbing

Prof. Dr. Ir. Suhono Harso Supangkat, M.Eng.
NIP. 196212031988111001

DAFTAR ISI

DAFTAR GAMBAR	iv
DAFTAR TABEL	v
DAFTAR KODE	vi
I PENDAHULUAN	1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	3
I.3 Tujuan	3
I.4 Batasan Masalah	4
I.5 Metodologi	4
II STUDI LITERATUR	8
II.1 Hipertensi	8
II.1.1 Klasifikasi Hipertensi	9
II.1.2 Faktor Risiko	10
II.1.2.1 Faktor Risiko Tidak Dapat Dimodifikasi	10
II.1.2.2 Faktor Risiko Dapat Dimodifikasi	11
II.2 Machine Learning	12
II.2.1 Gradient Boosting	12
II.2.2 Extreme Gradient Boosting (XGBoost)	13
II.3 Artificial Intelligence	14
II.3.1 Explainable Artificial Intelligence (XAI)	15
II.3.1.1 Shapley Additive Explanation (SHAP)	15
II.3.1.2 LIME	15
II.3.1.3 Analisis Komparatif SHAP dan LIME	16
II.4 Large Language Model (LLM)	16
II.4.1 Vector Database	17
II.4.2 Keterbatasan LLM	18
II.4.3 Mengatasi Keterbatasan LLM	19
II.5 Retrieval-Augmented Generation (RAG)	19
II.5.1 Kapabilitas RAG	20
II.5.2 Limitasi Teknis RAG	20
II.5.3 RAG Dalam Domain Medis	21
II.5.4 Retrieval Augmented Generation Assessment (RAGAS)	21

II.6 Tinjauan Penelitian Sebelumnya	23
---	----

DAFTAR GAMBAR

II.1	Diagram Patofisiologi Mekanisme RAAS dalam Meningkatkan Tekanan Darah	9
II.2	Visualisasi data vector database	18
II.3	Visualisasi query vector database	18

DAFTAR TABEL

I.1	Perbandingan Statistik Hipertensi Global dan Nasional	2
I.2	Rencana Implementasi Metodologi CRISP-DM	7
II.1	Studi Sebelumnya	24

DAFTAR KODE

BAB I

PENDAHULUAN

I.1 Latar Belakang

Hipertensi merupakan tantangan kesehatan masyarakat global dan faktor risiko utama yang berkontribusi pada morbiditas dan mortalitas akibat penyakit kardiovaskular, seperti stroke dan gagal jantung (Reges et al., 2020). Data WHO (2023) mengindikasikan bahwa 1,28 miliar orang dewasa di seluruh dunia hidup dengan hipertensi, sebuah angka yang sejalan dengan tingginya prevalensi di Indonesia. Di Indonesia, transisi epidemiologi penyakit tidak menular ini menunjukkan tren yang paralel dengan situasi global, namun dengan karakteristik demografis yang semakin mengkhawatirkan. Berdasarkan hasil Survei Kesehatan Indonesia (SKI) tahun 2023, terjadi pergeseran kerentanan yang signifikan ke arah populasi yang lebih muda. Data SKI 2023 mencatat prevalensi hipertensi berdasarkan pengukuran fisik mencapai 10,7% pada kelompok usia remaja akhir hingga dewasa muda (18-24 tahun) dan melonjak menjadi 17,4% pada kelompok usia produktif awal (25-34 tahun) (Bkpk, 2024).

Lebih jauh lagi, terdapat disparitas yang tajam antara hipertensi yang terdiagnosis oleh tenaga kesehatan dengan hipertensi yang terdeteksi melalui pengukuran survei. Pada kelompok usia 18-24 tahun, prevalensi berdasarkan diagnosis dokter hanya tercatat sebesar 0,4%, sangat jauh di bawah angka hasil pengukuran aktual sebesar 10,7%. Kesenjangan data yang lebar ini (*"gap of awareness"*) mengindikasikan kegagalan sistemik dalam strategi deteksi dini konvensional.

Data pada Tabel I.1 menegaskan bahwa tantangan utama di Indonesia bukan hanya pada pengobatan, melainkan pada deteksi dini. Metode skrining yang ada saat ini terbukti tidak efektif menjangkau populasi muda yang merasa dirinya sehat (Nong et al., 2024).

Tabel I.1 Perbandingan Statistik Hipertensi Global dan Nasional

Indikator	Global (WHO 2024)	Indonesia Usia 18-24 (SKI 2023)	Indonesia Usia 25-34 (SKI 2023)
Total Estimasi	1,4 Miliar	-	-
Prevalensi Pengukuran	33%	10,7%	17,4%
Prevalensi Diagnosis	-	0,4%	1,8%
Tingkat Kesadaran	~44% (Unaware)	~96% (Gap)	~89% (Gap)
Tingkat Terkontrol	~23%	Data Tidak Spesifik	Data Tidak Spesifik

Dalam praktik klinis tradisional, penilaian risiko penyakit kardiovaskular sering kali bergantung pada sistem skor standar seperti *Framingham Risk Score* (FRS). Meskipun metode ini telah digunakan secara luas, berbagai studi menunjukkan keterbatasan validitasnya ketika diterapkan pada populasi Asia, termasuk Indonesia (Kasim et al., 2023). Model-model ini dikembangkan berdasarkan data kohort populasi Barat yang memiliki profil genetik dan pola diet berbeda. Populasi Asia cenderung memiliki sensitivitas garam yang lebih tinggi dan risiko stroke yang lebih dominan.

Pendekatan berbasis kecerdasan buatan, khususnya *Machine Learning* (ML), menawarkan alternatif yang menjanjikan. Algoritma ML terkini memiliki kemampuan superior dalam memodelkan hubungan non-linier yang kompleks antara berbagai variabel risiko (Tarimana et al., 2024). Studi terbaru menunjukkan bahwa model ML mampu mencapai akurasi klasifikasi risiko yang jauh lebih tinggi dibandingkan regresi logistik tradisional.

Meskipun ML menawarkan performa tinggi, adopsi teknologi ini terhambat oleh masalah "*black box*", di mana model menghasilkan prediksi tanpa menyertakan alasan yang dapat dipahami manusia. Dalam konteks medis, opasitas ini memunculkan masalah kepercayaan. Metode *Explainable AI* (XAI), menjadi krusial untuk menjembatani kesenjangan ini dengan memberikan visualisasi dampak spesifik dari setiap variabel (Feretzakis et al., 2024).

Selain prediksi, keberhasilan manajemen hipertensi bergantung pada edukasi. Kemajuan *Large Language Models* (LLM) memungkinkan adanya asisten kesehatan virtual. Namun, LLM memiliki risiko halusinasi. Solusi yang lebih tangguh adalah arsitektur *Retrieval-Augmented Generation* (RAG), yang menggabungkan kemampuan generatif LLM dengan sistem pencarian informasi berbasis dokumen medis terverifikasi (Nishisako et al., 2025). Oleh karena itu, penelitian ini mengusulkan sistem informasi terintegrasi yang menggabungkan tiga pilar, yaitu ML untuk

prediksi presisi, XAI (SHAP) untuk transparansi, dan Chatbot RAG untuk edukasi kesehatan yang akurat.

I.2 Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah dalam penelitian ini adalah:

1. Bagaimana merancang dan melatih model *Machine Learning* yang mampu mengolah variabel demografis, fisiologis, dan gaya hidup untuk memprediksi risiko hipertensi dengan tingkat akurasi, presisi, dan sensitivitas yang lebih tinggi dibandingkan metode deteksi konvensional?
2. Bagaimana mengimplementasikan metode *Explainable AI* (XAI) untuk menghasilkan visualisasi interpretasi yang transparan baik secara global maupun lokal per individu, sehingga faktor determinan risiko dapat dipahami dan diverifikasi oleh pengguna?
3. Bagaimana mengembangkan arsitektur chatbot cerdas menggunakan teknik *Retrieval-Augmented Generation* (RAG) yang terintegrasi dengan basis pengetahuan dokumen medis terverifikasi untuk meminimalkan halusinasi dan menyediakan jawaban edukatif yang akurat?
4. Bagaimana kinerja sistem prediksi risiko hipertensi berbasis machine learning yang diintegrasikan dengan chatbot LLM berbasis Retrieval-Augmented Generation (RAG) jika dievaluasi secara komprehensif berdasarkan aspek performa prediksi, transparansi model (explainability), serta kualitas layanan informasi yang diberikan kepada pengguna?

I.3 Tujuan

Tujuan utama pelaksanaan Tugas Akhir ini adalah:

1. Membangun dan mengoptimasi model klasifikasi risiko hipertensi menggunakan algoritma *Machine Learning* terpilih (seperti XGBoost/Random Forest) dengan target metrik evaluasi (Akurasi, F1-Score, AUC-ROC) melampaui 85%.
2. Mengintegrasikan pustaka SHAP ke dalam alur kerja prediksi untuk menghasilkan penjelasan intuitif berupa *Force Plot* (lokal) dan *Summary Plot* (global).

3. Merancang sistem chatbot yang memanfaatkan LLM dengan arsitektur RAG, difokuskan pada mekanisme *retrieval* yang efisien dari korpus dokumen kesehatan resmi untuk meminimalkan halusinasi.
4. Melakukan pengujian menyeluruh terhadap seluruh komponen sistem, mencakup evaluasi teknis model ML, kualitas penjelasan SHAP, serta evaluasi kinerja chatbot.

I.4 Batasan Masalah

Batasan-batasan masalah yang diambil dalam pelaksanaan tugas akhir ini adalah sebagai berikut:

1. Penelitian ini menggunakan data sekunder yang bersifat publik dan telah dianonimisasi (seperti dataset dari Kaggle atau repositori UCI) untuk melindungi privasi. Penggunaan data rekam medis riil rumah sakit tidak dilakukan karena kendala etika dan perizinan.
2. Eksplorasi algoritma dibatasi pada metode *Supervised Learning* pada data tabular. Tidak membahas *Deep Learning* untuk citra medis.
3. Fitur chatbot dikembangkan khusus untuk domain edukasi hipertensi, pencegahan, dan gaya hidup sehat. Basis pengetahuan dibatasi pada dokumen resmi (Kemenkes/WHO). Sistem bukan pengganti diagnosis medis dokter.
4. Sistem akan diimplementasikan dalam bentuk purwarupa aplikasi berbasis web (*web-based application*).

I.5 Metodologi

Penelitian ini mengadopsi kerangka kerja metodologi *CRISP-DM* (*Cross-Industry Standard Process for Data Mining*) yang diintegrasikan dengan siklus pengembangan perangkat lunak. Berikut adalah rincian tahapan metodologi yang akan dilaksanakan:

1. **Pemahaman Bisnis dan Masalah (*Business Understanding*)**

Tahap inisiasi ini berfokus pada pendalaman konteks masalah hipertensi di Indonesia. Kegiatan yang dilakukan meliputi studi literatur pada epidemiologis penyakit hipertensi, di mana penulis menganalisis laporan SKI 2023 dan dokumen WHO 2024 untuk memetakan tren prevalensi, kesenjangan deteksi, dan demografi risiko (World Health Organization, 2025). Ini penting untuk

menentukan variabel apa saja yang krusial untuk dimasukkan ke dalam model prediksi. Penulis menetapkan metrik keberhasilan kuantitatif, seperti target akurasi model lebih tinggi dari 85%, tingkat sensitivitas (*Recall*) yang tinggi untuk meminimalkan pasien berisiko yang tidak terdeteksi (*False Negative*), serta kriteria penerimaan untuk respon chatbot agar bebas dari halusinasi fatal.

2. Pemahaman Data (*Data Understanding*)

Tahap ini melibatkan akuisisi dan eksplorasi data mentah untuk memastikan kualitasnya sebelum pemrosesan lebih lanjut. Pada tahap ini, dilakukan pengunduhan dataset prediksi risiko hipertensi dari repositori publik seperti Kaggle atau dari sumber ternama seperti UCI Machine Learning Repository atau Indonesia Family Life Survey (IFLS). Setelahnya, dilakukan analisis statistik deskriptif dan visualisasi data untuk memahami distribusi setiap fitur seperti usia, BMI, dan fitur-fitur relevan lainnya. Setelahnya, analisis korelasi dilakukan untuk melihat hubungan antar variabel dan mengidentifikasi multikolinearitas atau korelasi kuat intens antar dua variabel tersebut yang mempersulit menentukan pengaruh unik dari masing-masing variabel. Pengecekan keseimbangan kelas target, khususnya pada proporsi pasien hipertensi dan normal juga dilakukan untuk menentukan strategi penanganan data yang tidak seimbang (*imbalanced data*) nantinya.

3. Persiapan Data (*Data Preparation*)

Ini adalah tahap paling krusial dan memakan waktu, bertujuan mengubah data mentah menjadi format yang siap dilatih oleh model ML. Pada tahap ini, ditangani nilai yang hilang (*missing values*) dengan metode imputasi yang relevan seperti mean/median/mode atau KNN imputation dan membuang data duplikat atau outlier ekstrim yang tidak masuk akal secara medis (Park et al., 2024). Setelahnya, dilakukan normalisasi atau standarisasi pada fitur numerik seperti usia dan tekanan darah agar memiliki skala yang seragam. Fitur kategorikal seperti jenis kelamin dan status merokok akan diubah menjadi format numerik menggunakan teknik *One-Hot Encoding* atau *Label Encoding*. Setelahnya, dilakukan pembagian data (*Data Splitting*) di mana dataset dibagi menjadi tiga bagian: data latih (*training set*) sekitar 70-80%, data validasi sekitar 10-15%, dan data uji (*test set*) sekitar 10-15% untuk dievaluasi secara objektif. Teknik *Stratified Sampling* akan digunakan untuk menjaga proporsi kelas target yang seimbang di setiap bagian.

4. Pemodelan dan Pengembangan XAI (*Modeling & Explainability*)

Ini adalah tahap inti di mana algoritma cerdas dibangun dan dilatih.

- Pada tahap ini dilakukan pelatihan model dengan beberapa algoritma kandidat yaitu Logistic Regression, Random Forest, dan XGBoost menggunakan data latih. Teknik *Cross-Validation* (misalnya k-fold) diterapkan untuk mencegah *overfitting* dan memastikan generalisasi model (Kutlu et al., 2024).
- Selanjutnya, dilakukan optimasi model dengan melakukan *Hyperparameter Tuning* menggunakan *Grid Search* atau *Random Search* untuk mencari konfigurasi parameter terbaik bagi algoritma terpilih guna memaksimalkan metrik performa.
- Setelah itu, algoritma *TreeExplainer* akan diaplikasikan khusus untuk model berbasis pohon dari pustaka SHAP pada model yang telah dilatih. Proses ini akan menghasilkan SHAP values untuk setiap instans data, yang kemudian digunakan untuk membangkitkan visualisasi *Summary Plot* untuk menggambarkan fitur global, dan *Force/Waterfall Plot* untuk menjelaskan kontribusi setiap fitur pada prediksi lokal (Feretakis et al., 2024).

5. Pengembangan Chatbot RAG (*RAG Chatbot Development*)

Pengembangan modul chatbot dilakukan secara paralel dengan pemodelan ML. Pertama-tama, penulis melakukan konstruksi basis pengetahuan, di mana penulis mengumpulkan dokumen PDF terpercaya seperti pedoman Kemenkes atau WHO fact sheets. Dokumen ini kemudian dipecah menjadi potongan-potongan teks kecil (*chunking*). Potongan-potongan tersebut akan di-konversi menjadi representasi vektor (*embeddings*) menggunakan model embedding dan menyimpannya dalam basis data vektor yaitu *Vector Database* (InterSystems, 2025). Selanjutnya adalah tahap implementasi proses *retrieval* dan *generation*, di mana penulis membangun logika sistem untuk pertanyaan pengguna (*query*) diubah menjadi vektor, dicocokkan dengan vektor dokumen yang paling relevan di basis data (*semantic search*), dan kemudian diteruskan bersama *prompt* instruksi ke LLM untuk menghasilkan jawaban (Makebot, 2025).

6. Evaluasi (*Evaluation*)

Tahap ini berisikan tahap verifikasi menyeluruh sebelum sistem dianggap layak. Pertama-tama dilakukan evaluasi pada model ML, di mana dilakukan pengujian performa model pada data uji menggunakan metrik Akurasi, Presisi, Recall, F1-Score, dan AUC-ROC. Fokus khusus diberikan pada *Recall*

untuk meminimalkan risiko tidak terdeteksinya kasus positif hipertensi (Yaseen & Rashid, 2025). Selanjutnya dilakukan evaluasi RAG Chatbot, di mana kualitas jawaban chatbot diuji. Evaluasi akan menggunakan pendekatan kualitatif yaitu penilaian manusia/pakar terhadap relevansi dan kebenaran fakta atau metrik otomatis seperti RAGAS score untuk *faithfulness* dan *answer relevance* guna memastikan minimnya halusinasi (Primawan, 2025). Lalu dilakukan evaluasi antarmuka di mana dilakukan pengujian fungsionalitas dari aplikasi web untuk memastikan visualisasi SHAP muncul dengan benar dan interaksi chatbot berjalan lancar melalui *User Acceptance Testing*.

7. Penyebaran (*Deployment*) - Tahap Prototype

Langkah terakhir dalam lingkup tugas akhir ini adalah mengemas model dan chatbot ke dalam antarmuka aplikasi web sehingga dapat didemonstrasikan dan diakses oleh pengguna akhir secara simulasi. Sistem ini akan menampilkan formulir input data kesehatan, hasil prediksi risiko beserta grafik penjelasan SHAP, dan jendela obrolan untuk konsultasi lanjutan.

Tabel I.2 berikut merangkum pemetaan antara tahapan metodologi CRISP-DM dengan aktivitas spesifik penelitian ini.

Tabel I.2 Rencana Implementasi Metodologi CRISP-DM

Fase CRISP-DM	Aktivitas Utama	Luaran (Output)
<i>Business Understanding</i>	Studi literatur hipertensi (WHO/SKI), penentuan tujuan metrik.	Definisi masalah & KPI.
<i>Data Understanding</i>	Koleksi dataset, EDA, analisis korelasi fitur.	Laporan statistik deskriptif.
<i>Data Preparation</i>	<i>Cleaning, encoding, scaling, splitting</i> data.	Dataset bersih siap latih.
<i>Modeling</i>	Training XGBoost/RF, Tuning parameter, Integrasi SHAP.	Model ML teroptimasi & Modul XAI.
<i>Evaluation</i>	Hitung akurasi/F1-Score, Uji halusinasi Chatbot.	Laporan performa & validasi.
<i>Deployment</i>	Integrasi ke Web App (Streamlit/Flask).	Prototipe Sistem Informasi.

BAB II

STUDI LITERATUR

II.1 Hipertensi

Hipertensi secara global didefinisikan sebagai suatu kondisi hemodinamik kronis di mana tekanan darah di arteri meningkat secara persisten. Menurut konsensus medis internasional terbaru, hipertensi bukan sekadar angka tekanan darah yang tinggi, melainkan sindrom kardiovaskular progresif yang memicu perubahan struktural dan fungsional pada pembuluh darah serta organ vital (Unger et al., 2020). Dalam konteks fisiologis, kondisi ini terjadi ketika tekanan darah sistolik (TDS) berada pada nilai 140 mmHg atau lebih, dan/atau tekanan darah diastolik (TDD) berada pada nilai 90 mmHg atau lebih, setelah dilakukan pengukuran berulang di klinik (Williams et al., 2024)

Penyakit ini sering disebut sebagai *the silent killer* karena sebagian besar penderita tidak menunjukkan gejala klinis yang spesifik hingga terjadi kerusakan organ target atau *Target Organ Damage* (TOD) seperti hipertrofi ventrikel kiri, gagal ginjal kronis, atau retinopati (Mills et al., 2020). Prevalensi hipertensi terus meningkat secara global, didorong oleh penuaan populasi dan pergeseran gaya hidup, di mana data terbaru menunjukkan bahwa lebih dari 1,28 miliar orang dewasa berusia 30–79 tahun di seluruh dunia hidup dengan hipertensi, dengan dua pertiga di antaranya tinggal di negara berpenghasilan rendah dan menengah (WHO, 2023).

Di Indonesia, hipertensi masih menjadi tantangan kesehatan utama dengan tingkat pengendalian yang rendah. Studi epidemiologi terbaru menunjukkan bahwa prevalensi hipertensi di Indonesia tidak hanya didominasi oleh lansia, tetapi mulai merambah ke populasi usia produktif akibat transisi nutrisi dan penurunan aktivitas fisik (Arifin et al., 2022). Patofisiologi hipertensi melibatkan interaksi kompleks antara curah jantung dan resistensi vaskular perifer, yang diatur oleh sistem saraf simpatis, sistem renin-angiotensin-aldosteron (RAAS), dan keseimbangan cairan tubuh (Ha-

Il et al., 2021). Ketidakseimbangan pada salah satu mekanisme ini dapat memicu vasokonstriksi berkepanjangan yang berujung pada elevasi tekanan darah sistemik.

Sumber: Sparks et al., 2022

Gambar II.1 Diagram Patofisiologi Mekanisme RAAS dalam Meningkatkan Tekanan Darah

II.1.1 Klasifikasi Hipertensi

Klasifikasi tekanan darah merupakan pedoman klinis fundamental yang digunakan untuk menentukan stratifikasi risiko dan strategi intervensi medis. Meskipun terdapat beberapa pedoman internasional, klasifikasi yang paling banyak diadopsi dalam literatur terkini merujuk pada pedoman *International Society of Hypertension* (ISH) 2020 dan *European Society of Hypertension* (ESH) 2023 yang berupaya menyederhanakan kategorisasi untuk kemudahan praktik klinis (Mancia et al., 2023).

Perbedaan mendasar dalam klasifikasi modern dibandingkan pedoman lama seperti JNC 7 adalah penekanan pada kategori "Normal-Tinggi" atau pre-hipertensi sebagai sinyal peringatan dini. Klasifikasi ini penting dalam pengembangan model prediksi berbasis kecerdasan buatan karena memungkinkan algoritma untuk mendeteksi pergeseran pola data pasien dari fase normal menuju fase patologis sebelum diagnosis klinis tegak (Schutte et al., 2021). Klasifikasi hipertensi dibagi menjadi beberapa kategori sebagai berikut:

1. Normal

Tekanan darah sistolik < 130 mmHg dan diastolik < 85 mmHg dianggap sebagai kondisi ideal dengan risiko kejadian kardiovaskular terendah (Stergiou et al., 2021).

2. High-Normal

Rentang sistolik 130–139 mmHg dan/atau diastolik 85–89 mmHg. Kategori ini memerlukan pemantauan ketat karena individu dalam kelompok ini memiliki probabilitas tinggi untuk berkembang menjadi hipertensi menetap jika tidak dilakukan modifikasi gaya hidup (Whelton et al., 2022).

3. Hipertensi Derajat 1

Ditandai dengan sistolik 140–159 mmHg dan/atau diastolik 90–99 mmHg. Pada tahap ini, intervensi farmakologis sering kali mulai dipertimbangkan bersamaan dengan perubahan gaya hidup, tergantung pada profil risiko kardiovaskular total pasien (Unger et al., 2020).

4. Hipertensi Derajat 2

Tekanan sistolik ≥ 160 mmHg dan/atau diastolik ≥ 100 mmHg. Kondisi ini me-

merlukan penanganan segera untuk mencegah kejadian akut seperti stroke atau infark miokard (Byrd et al., 2019).

Selain klasifikasi berbasis derajat, hipertensi juga diklasifikasikan berdasarkan etiologinya menjadi hipertensi primer (esensial) dan hipertensi sekunder. Hipertensi primer mencakup 90-95% dari seluruh kasus dan tidak memiliki penyebab tunggal yang dapat diidentifikasi, melainkan hasil dari interaksi multifaktorial genetik dan lingkungan (Rimoldi et al., 2020). Sedangkan hipertensi sekunder disebabkan oleh kondisi medis yang mendasarinya, seperti penyakit parenkim ginjal, gangguan endokrin, atau penggunaan obat-obatan tertentu (Charles et al., 2021).

II.1.2 Faktor Risiko

Faktor risiko hipertensi dibagi menjadi dua klaster utama, yaitu faktor risiko yang tidak dapat dimodifikasi (*non-modifiable risk factors*) dan faktor risiko yang dapat dimodifikasi (*modifiable risk factors*). Identifikasi faktor-faktor ini krusial karena interaksi antar variabel tersebutlah yang akan dianalisis oleh model komputasi untuk menghasilkan prediksi yang akurat (Hegde & Solomon, 2022).

II.1.2.1 Faktor Risiko Tidak Dapat Dimodifikasi

1. Usia

Penuaan adalah determinan paling kuat terhadap peningkatan tekanan darah. Seiring bertambahnya usia, terjadi kekakuan arteri (*arterial stiffness*) akibat hilangnya serat elastin dan penumpukan kolagen pada dinding pembuluh darah, yang secara langsung meningkatkan tekanan sistolik (Lacolley et al., 2020).

2. Jenis Kelamin

Studi menunjukkan bahwa pria memiliki prevalensi hipertensi yang lebih tinggi dibandingkan wanita pada usia muda hingga paruh baya. Namun, setelah masa menopause, risiko pada wanita meningkat tajam dan sering kali melampaui pria akibat penurunan efek protektif hormon estrogen terhadap vaskular (Reckelhoff, 2021).

3. Genetik dan Riwayat Keluarga

Variasi genetik berkontribusi sekitar 30–50% terhadap variabilitas tekanan darah populasi. Individu dengan riwayat keluarga hipertensi memiliki risiko dua kali lipat lebih besar untuk mengembangkan kondisi serupa, yang dimediasi oleh pewarisan polimorfisme gen yang mengatur sistem RAAS (Padmanabh-

an et al., 2019).

II.1.2.2 Faktor Risiko Dapat Dimodifikasi

1. Obesitas dan Indeks Massa Tubuh (IMT)

Terdapat korelasi linier yang kuat antara berat badan dan tekanan darah. Jaringan adiposa yang berlebih, terutama lemak visceral, memproduksi sitokin pro-inflamasi dan mengaktivasi sistem saraf simpatis yang memicu retensi natrium ginjal dan hipertensi (Hall et al., 2019).

2. Asupan Garam (Natrium)

Konsumsi natrium yang berlebihan adalah penyebab utama hipertensi sensitif-garam. Mekanisme ini melibatkan peningkatan volume cairan ekstraseluler dan disfungsi endotel. Penelitian terbaru menegaskan bahwa pengurangan asupan garam harian secara signifikan menurunkan tekanan darah pada populasi hipertensi maupun normotensi (Grillo et al., 2019).

3. Kurangnya Aktivitas Fisik

Gaya hidup sedentari melemahkan kebugaran kardiorespirasi dan resistensi insulin. Latihan fisik teratur terbukti dapat menurunkan resistensi vaskular sistemik melalui perbaikan fungsi endotel dan penurunan aktivitas simpatis (Boutcher & Boutcher, 2020).

4. Merokok

Zat kimia dalam rokok, terutama nikotin, memicu pelepasan katekolamin yang menyebabkan vasokonstriksi akut dan peningkatan denyut jantung. Paparan kronis merusak lapisan endotel pembuluh darah dan mempercepat proses aterosklerosis yang memperburuk hipertensi (Benowitz & Burbank, 2021).

5. Dislipidemia

Kadar kolesterol abnormal, khususnya peningkatan LDL dan trigliserida, berkontribusi pada pembentukan plak aterosklerosis. Plak ini mempersempit lumen pembuluh darah dan meningkatkan rigiditas dinding arteri, yang secara mekanis meningkatkan tekanan darah (Nolan et al., 2022).

6. Faktor Psikososial dan Stres

Stres kronis memicu respons neurohormonal jangka panjang melalui aksis hipotalamus-hipofisis-adrenal, yang menghasilkan kortisol berlebih. Kondisi ini berhubungan erat dengan peningkatan tekanan darah yang menetap dan risiko kejadian kardiovaskular (Osborne et al., 2020).

II.2 Machine Learning

Klasifikasi pada data medis merupakan tugas pembelajaran mesin terawasi atau *Supervised Machine Learning* yang bertujuan memetakan variabel input ke dalam label kategori diskrit. Dalam konteks prediksi hipertensi, model dilatih untuk memisahkan data pasien ke dalam kelas risiko positif atau negatif berdasarkan pola historis yang terdapat pada dataset pelatihan (Sarkar dkk., 2020). Akurasi dan keandalan model klasifikasi sangat bergantung pada pemilihan algoritma yang mampu menangani karakteristik data tabular yang sering kali memiliki distribusi tidak seimbang.

II.2.1 Gradient Boosting

Gradient Boosting adalah teknik *machine learning* berbasis *ensemble* yang dikembangkan untuk meningkatkan akurasi prediksi dengan cara menggabungkan sejumlah model prediksi sederhana (*weak learners*) umumnya berupa *decision trees* menjadi satu model prediksi yang kuat dan komprehensif. Prinsip dasar dari algoritma ini adalah pembentukan model secara bertahap (*stage-wise*), di mana setiap model baru yang ditambahkan bertujuan untuk memperbaiki kesalahan (*residual errors*) yang dihasilkan oleh gabungan model-model sebelumnya (Guo & Zhang, 2024).

Dalam konteks pengembangan sistem prediksi risiko penyakit seperti hipertensi, Gradient Boosting memiliki keunggulan signifikan dibandingkan metode statistik konvensional. Algoritma ini mampu menangani hubungan non-linear yang kompleks antar variabel klinis pasien, seperti interaksi antara indeks massa tubuh (BMI), tekanan darah sistolik, dan riwayat genetik, yang seringkali sulit dimodelkan oleh *Logistic Regression* (Muftisany, 2024). Proses matematis Gradient Boosting melibatkan optimasi fungsi kerugian (*loss function*) yang dapat disesuaikan, memungkinkannya untuk meminimalkan bias prediksi secara iteratif pada data rekam medis yang seringkali memiliki tingkat *noise* atau variabilitas tinggi.

Penerapan Gradient Boosting dalam studi epidemiologi modern menunjukkan performa yang konsisten dalam klasifikasi risiko kesehatan. Sebuah studi terbaru pada populasi pasien di Indonesia menunjukkan bahwa model berbasis *boosting* mampu mencapai akurasi diagnostik dan nilai *Area Under Curve* (AUC) yang lebih tinggi dibandingkan algoritma tunggal lainnya dalam mendeteksi hipertensi dini (Wibawa et al., 2025). Selain akurasi, arsitektur Gradient Boosting juga sangat kompatibel dengan metode *Explainable Artificial Intelligence* (XAI) seperti SHAP (*SHapley Additive exPlanations*). Hal ini memungkinkan sistem untuk tidak hanya memprediksi probabilitas hipertensi, tetapi juga memberikan transparansi mengenai fitur

klinis mana yang paling berkontribusi terhadap diagnosis tersebut, yang merupakan elemen krusial untuk kepercayaan klinis (Li et al., 2025).

Secara umum, jika diberikan fungsi tujuan untuk meminimalkan kesalahan prediksi pada data latih $S = \{(x_i, y_i)\}_{i=1}^n$, Gradient Boosting akan memperbarui model $\mathcal{F}(x)$ pada setiap iterasi ke- m dengan menambahkan estimator baru $h_m(x)$ sebagai berikut:

$$\mathcal{F}_m(x) = \mathcal{F}_{m-1}(x) + \nu \cdot h_m(x) \quad (\text{II.1})$$

Di mana ν adalah *learning rate* yang mengontrol kontribusi setiap pohon untuk mencegah *overfitting*, sebuah mekanisme regularisasi yang sangat penting saat bekerja dengan dataset kesehatan yang terbatas atau tidak seimbang (Zhang et al., 2025).

II.2.2 Extreme Gradient Boosting (XGBoost)

Extreme Gradient Boosting atau XGBoost adalah pengembangan tingkat lanjut dari algoritma *Gradient Boosting Machine* (GBM) yang dirancang untuk memiliki efisiensi komputasi tinggi, skalabilitas, dan kinerja prediksi yang lebih akurat dibandingkan pendahulunya. XGBoost bekerja dengan prinsip *ensemble learning*, di mana algoritma ini menggabungkan hasil dari banyak model prediksi lemah (*weak learners*) biasanya berupa *decision trees* secara berurutan untuk membentuk satu model prediksi yang kuat dan stabil (Emmanuel & Ok, 2025).

Dalam konteks pengembangan sistem prediksi risiko kesehatan seperti hipertensi, XGBoost memiliki keunggulan signifikan dibandingkan metode tradisional. Algoritma ini dilengkapi dengan mekanisme *regularization* (L1 dan L2) yang terintegrasi di dalam fungsi objektifnya. Fitur ini berfungsi untuk mengontrol kompleksitas model dan mencegah terjadinya *overfitting*, yaitu kondisi di mana model terlalu menghafal data latih namun gagal memprediksi data baru dengan akurat, yang sering menjadi masalah utama dalam analisis data medis yang memiliki *noise* tinggi (Guo & Zhang, 2024).

Secara matematis, jika diberikan sekumpulan data dengan fitur m dan jumlah sampel n , XGBoost meminimalkan fungsi objektif yang terdiri dari fungsi *loss* dan penalti regularisasi. Berbeda dengan Gradient Boosting standar yang hanya mengoptimalkan *loss function*, fungsi objektif pada XGBoost ($\mathcal{L}$) dapat didefinisikan sebagai berikut:

$$\mathcal{L}(\phi) = \sum_i l(y_i, \hat{y}_i) + \sum_k \Omega(f_k) \quad (\text{II.2})$$

Di mana l adalah fungsi *loss* yang mengukur perbedaan antara prediksi ($\hat{y}_i$) dan nilai aktual (y_i), sedangkan Ω adalah komponen regularisasi yang mengontrol kompleksitas *tree* (pohon keputusan) untuk mencegah *overfitting*. Komponen regularisasi ini dihitung dengan rumus:

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda ||w||^2 \quad (\text{II.3})$$

Parameter γ (gamma) dan λ (lambda) dalam persamaan di atas berperan penting dalam proses *pruning* atau pemangkasan pohon keputusan, yang menjadikan XGBoost sangat *robust* terhadap data yang tidak seimbang (*imbalanced data*) yang sering ditemukan dalam dataset pasien hipertensi (Emmanuel & Ok, 2025).

Relevansi XGBoost dalam penelitian hipertensi telah dibuktikan dalam berbagai studi terbaru. Penelitian yang dilakukan oleh Zhang et al. (2025) menunjukkan bahwa XGBoost mampu memberikan performa stratifikasi risiko hipertensi yang lebih unggul dibandingkan *Logistic Regression* tradisional, dengan nilai akurasi dan *Area Under Curve* (AUC) yang lebih tinggi secara konsisten. Selain itu, XGBoost juga mendukung integrasi dengan metode *Explainable Artificial Intelligence* (XAI) seperti SHAP (*Shapley Additive exPlanations*), yang memungkinkan peneliti untuk tidak hanya mendapatkan hasil prediksi, tetapi juga memahami faktor risiko dominan (seperti usia, BMI, atau tekanan darah sistolik) yang berkontribusi terhadap keputusan model tersebut (Li et al., 2025).

II.3 Artificial Intelligence

Artificial Intelligence (AI) atau kecerdasan buatan merujuk pada simulasi proses kecerdasan manusia oleh sistem mesin, terutama sistem komputer. Proses ini mencakup pembelajaran (*learning*) yaitu perolehan informasi dan aturan untuk menggunakan informasi tersebut, penalaran (*reasoning*) yaitu penggunaan aturan untuk mencapai kesimpulan perkiraan atau pasti, dan koreksi diri (*self-correction*) (Davenport & Kalakota, 2019).

Dalam konteks revolusi industri 4.0, teknologi AI telah menjadi pilar utama yang memungkinkan transformasi operasional melalui otomatisasi cerdas dan pengambil-

an keputusan berbasis data (Javaid et al., 2022). Adopsi AI di berbagai sektor, termasuk kesehatan, telah terbukti mampu mengoptimalkan alur kerja, meminimalkan kesalahan manusia, dan meningkatkan efisiensi operasional secara signifikan. Kemampuan sistem untuk mempelajari pola dari data historis memungkinkan organisasi untuk memprediksi tren masa depan dengan akurasi yang lebih tinggi dibandingkan metode konvensional (Secinaro et al., 2021). Secara spesifik, integrasi AI dalam sistem pemrosesan data memungkinkan reduksi *lead time*, peningkatan fleksibilitas sistem, serta optimalisasi alokasi sumber daya yang tersedia (Haleem et al., 2022).

II.3.1 Explainable Artificial Intelligence (XAI)

Penerapan *Machine Learning* dalam praktik klinis sering terhambat oleh sifat *black box* dari model canggih seperti XGBoost yang sulit diinterpretasikan oleh manusia. *Explainable Artificial Intelligence* atau XAI hadir sebagai solusi untuk memberikan transparansi terhadap keputusan yang diambil oleh sistem cerdas (Adadi & Berrada, 2018). Transparansi ini krusial untuk membangun kepercayaan tenaga medis terhadap saran diagnosis yang diberikan oleh algoritma.

II.3.1.1 Shapley Additive Explanation (SHAP)

Metode SHAP merupakan pendekatan XAI yang mengadopsi konsep teori permainan kooperatif untuk menghitung kontribusi marginal setiap fitur terhadap hasil prediksi. Nilai Shapley menjamin konsistensi matematis dengan memastikan bahwa total kontribusi seluruh fitur sama dengan selisih antara prediksi aktual dan prediksi rata-rata model (Lundberg & Lee, 2017). Sifat aditif ini menjadikan SHAP sangat andal untuk audit medis karena memberikan penjelasan yang adil dan konsisten untuk setiap variabel risiko pasien.

II.3.1.2 LIME

Metode alternatif yang sering digunakan adalah *Local Interpretable Model-agnostic Explanations* atau LIME. LIME bekerja dengan cara melakukan perturbasi atau pengubahan acak di sekitar data *instance* untuk membangun model linear sederhana yang dapat dijelaskan secara lokal. Pendekatan ini berfokus pada pendekatan perilaku model di sekitar satu titik prediksi spesifik tanpa mencoba memahami model global secara keseluruhan.

II.3.1.3 Analisis Komparatif SHAP dan LIME

Meskipun LIME lebih cepat secara komputasi, metode ini memiliki kelemahan dalam hal stabilitas karena penjelasan yang dihasilkan dapat berubah-ubah pada setiap iterasi eksekusi untuk data yang sama (Molnar, 2020). Sebaliknya, SHAP menawarkan landasan teoretis yang lebih kuat melalui properti aksiomatik teori permainan yang menjamin keunikan solusi penjelasan. Oleh karena itu, penelitian ini memilih menggunakan SHAP karena stabilitas dan konsistensi penjelasan merupakan syarat mutlak dalam sistem pendukung keputusan medis yang menyangkut keselamatan pasien.

II.4 Large Language Model (LLM)

Large Language Model (LLM) merupakan evolusi mutakhir dalam domain *Artificial Intelligence*, khususnya dalam pemrosesan bahasa alami. LLM adalah model probabilitas yang dirancang untuk memahami, memproses, dan menghasilkan teks dengan tingkat koherensi yang menyerupai kemampuan manusia (Zhao et al., 2023). Arsitektur dasar dari teknologi ini mengandalkan teknik *Deep Learning* dan model statistik canggih untuk menganalisis korpus data teks dalam skala masif. Melalui pelatihan pada dataset berskala besar, model ini mampu mengidentifikasi pola linguistik yang kompleks, hubungan semantik antar kata, serta nuansa kontekstual yang terkandung dalam bahasa (Kasneci et al., 2023).

Dalam ranah *Generative AI*, kemampuan LLM tidak terbatas pada pemahaman teks semata, melainkan juga mencakup kemampuan untuk menciptakan konten orisinal yang mengadopsi gaya dan karakteristik data pelatihannya. Salah satu implementasi paling prominen dari teknologi ini adalah ChatGPT, sebuah model generatif yang dioptimalkan untuk dialog interaktif (OpenAI, 2023).

Model-model ini dilatih menggunakan pendekatan *Unsupervised Learning* atau *Self-Supervised Learning*, yang memungkinkan mereka mempelajari struktur bahasa tanpa memerlukan pelabelan data manual secara ekstensif (Brown et al., 2020). Fundamental teknologi di balik LLM adalah arsitektur *Transformer*, yang memperkenalkan mekanisme *attention* untuk menangani ketergantungan jarak jauh dalam urutan data. Hal ini memungkinkan model untuk mempertahankan konteks pembicaraan atau dokumen yang panjang, menjadikannya sangat efektif untuk aplikasi seperti penerjemahan otomatis, *chatbot* cerdas, dan pembuatan ringkasan teks otomatis (Vaswani et al., 2017; Naveed et al., 2023).

II.4.1 Vector Database

Dalam ekosistem pengembangan aplikasi berbasis AI modern, *Vector Database* memegang peranan vital sebagai infrastruktur penyimpanan data. Berbeda dengan basis data relasional tradisional yang menyimpan data dalam baris dan kolom, *Vector Database* dirancang khusus untuk menyimpan, mengelola, dan mengindeks data dalam format vektor berdimensi tinggi (Pan et al., 2023). Vektor ini, atau yang sering disebut sebagai *embeddings*, merupakan representasi matematis dari data tidak terstruktur seperti teks, gambar, audio, atau video. Keunggulan utama dari jenis basis data ini terletak pada kemampuannya melakukan pencarian semantik (*semantic search*) berdasarkan kemiripan vektor, bukan sekadar pencocokan kata kunci (Wang et al., 2024). Untuk menangani beban kerja komputasi yang berat dan memastikan skalabilitas, arsitektur *Vector Database* menerapkan beberapa mekanisme optimasi sistem:

1. Sharding

Teknik partisi horizontal yang mendistribusikan dataset vektor ke berbagai mesin atau *node* dalam sebuah kluster. Distribusi ini seringkali didasarkan pada fungsi *hash* atau rentang kunci tertentu untuk menyeimbangkan beban penyimpanan (Xu et al., 2022).

2. Partitioning

Strategi pembagian basis data menjadi segmen-segmen logis yang lebih kecil dan mudah dikelola. Kriteria partisi dapat disesuaikan berdasarkan kategori data, lokasi geografis, atau frekuensi akses data (Han et al., 2023).

3. Caching

Implementasi memori perantara berkecepatan tinggi (seperti RAM) untuk menyimpan data atau hasil kueri yang sering diakses. Mekanisme ini krusial untuk mengurangi latensi sistem dan meningkatkan *throughput* pengambilan data (Zhang et al., 2021).

4. Replication

Proses duplikasi data vektor ke beberapa *node* atau kluster berbeda. Replikasi menjamin ketersediaan data (*availability*) yang tinggi, durabilitas data terhadap kegagalan perangkat keras, serta peningkatan kinerja pembacaan data secara paralel (Kleppmann, 2021).

Pencarian dalam *Vector Database* umumnya menggunakan algoritma *Nearest Neighbor Search* (NNS) atau *Approximate Nearest Neighbor Search* (ANNS) untuk menemukan vektor yang memiliki jarak terdekat (paling mirip) dengan vektor kueri.

Sumber: Taipalus, 2024

Gambar II.2 Visualisasi data vector database

Mekanisme kerja *Vector Database* dapat diuraikan melalui tahapan berikut:

1. **Penyimpanan Data dan Embedding**

Sebelum disimpan, data mentah (objek) dikonversi menjadi format numerik (vektor) melalui proses *embedding*. Setiap vektor merepresentasikan fitur-fitur dari objek tersebut dalam ruang multidimensi (Reimers & Gurevych, 2019).

2. **Indexing**

Setelah vektor tersimpan, sistem melakukan pengindeksan untuk memetakan lokasi data. Pengindeksan dapat dilakukan secara manual atau otomatis (*on-the-fly*). Tujuan utama pengindeksan adalah mengorganisir struktur data sedemikian rupa sehingga proses pencarian dapat dilakukan dengan kompleksitas waktu yang minimal (Johnson et al., 2019).

3. **Query dan Analisis**

Saat pengguna memasukkan kueri (misalnya dalam bentuk teks), sistem pertama-tama mengubah kueri tersebut menjadi vektor menggunakan model *embedding* yang sama. Selanjutnya, sistem melakukan pencarian komparatif untuk menemukan vektor dalam basis data yang memiliki nilai kemiripan tertinggi dengan vektor kueri (Wang et al., 2021).

Sumber: Taipalus, 2024

Gambar II.3 Visualisasi query vector database

Peran *Vector Database* menjadi sangat strategis dalam implementasi *Generative AI*, khususnya untuk mendukung metode *Retrieval Augmented Generation* (RAG). Dengan menyediakan akses cepat ke basis pengetahuan eksternal yang relevan, *Vector Database* membantu model bahasa menghasilkan respons yang lebih akurat dan kontekstualisasi, mengurangi risiko halusinasi model (Lewis et al., 2020).

II.4.2 Keterbatasan LLM

Penerapan LLM di bidang medis menghadapi tantangan serius terkait fenomena halusinasi, yaitu kondisi saat model menghasilkan informasi yang terdengar meyakinkan namun faktanya salah atau dibuat-buat (Ji dkk., 2023). Selain itu, LLM memiliki batasan pengetahuan statis atau *knowledge cutoff* yang membuatnya tidak mengetahui informasi atau pedoman medis terbaru yang rilis setelah tanggal pelatihan model.

II.4.3 Mengatasi Keterbatasan LLM

Berbagai strategi dikembangkan untuk memitigasi keterbatasan tersebut. Salah satu pendekatan adalah *fine-tuning* yang melatih ulang model dengan dataset spesifik, namun metode ini membutuhkan sumber daya komputasi yang besar dan data berkualitas tinggi. Pendekatan alternatif yang lebih efisien adalah *In-Context Learning* melalui *prompt engineering* yang menyertakan informasi relevan langsung di dalam instruksi input.

II.5 Retrieval-Augmented Generation (RAG)

Retrieval Augmented Generation (RAG) adalah kerangka kerja arsitektur yang dirancang untuk meningkatkan kapabilitas *Large Language Models* (LLM) dengan mengintegrasikan sistem temu kembali informasi (*information retrieval*) eksternal. Metode ini mengatasi keterbatasan pengetahuan statis yang dimiliki oleh LLM pasca-pelatihan dengan memungkinkan model mengakses data terkini atau data spesifik domain yang tersimpan dalam basis data eksternal (Gao et al., 2023). Pendekatan ini secara efektif memitigasi isu "halusinasi" pada AI, di mana model menghasilkan informasi yang tampak meyakinkan namun faktualnya salah (Ji et al., 2023).

Secara operasional, RAG bekerja melalui tiga fase utama yang saling terintegrasi:

1. Retrieval

Tahap ini merupakan fondasi dari RAG, di mana sistem mencari dan mengambil informasi yang relevan dari basis pengetahuan eksternal berdasarkan *prompt* atau pertanyaan pengguna. Proses ini seringkali memanfaatkan *Vector Database*. Kueri pengguna dikonversi menjadi representasi vektor, yang kemudian digunakan untuk memindai basis data guna menemukan dokumen atau potongan informasi (*chunks*) yang memiliki kesamaan semantik tertinggi. Hasil dari proses ini adalah kumpulan konteks yang relevan dengan pertanyaan pengguna (Karpukhin et al., 2020).

2. Augmentation

Setelah informasi relevan berhasil diambil, tahap selanjutnya adalah memperkaya (*augment*) *prompt* asli pengguna dengan informasi tersebut. Sistem akan menyusun *prompt* baru yang menggabungkan pertanyaan asli pengguna dengan data yang ditemukan dari tahap *retrieval*. Proses ini dapat melibatkan restrukturisasi kalimat atau penambahan instruksi khusus agar LLM dapat memproses konteks tambahan tersebut secara efektif. Tujuannya adalah menyediakan "konteks" yang lengkap bagi model sebelum model mulai

menyusun jawaban (Lewis et al., 2020).

3. **Generation**

Pada tahap akhir ini, *prompt* yang telah diaugmentasi dikirimkan ke LLM. Model kemudian memproses input gabungan tersebut untuk menghasilkan respons teks yang koheren. Karena model memiliki akses ke fakta-fakta spesifik yang disediakan dalam *prompt*, jawaban yang dihasilkan cenderung lebih akurat, faktual, dan relevan dengan konteks pertanyaan, dibandingkan jika model hanya mengandalkan parameter internalnya sendiri (Shuster et al., 2021).

II.5.1 **Kapabilitas RAG**

Salah satu kapabilitas utama RAG adalah kemampuannya dalam memitigasi masalah halusinasi, yaitu kecenderungan LLM untuk menghasilkan respons yang fasih secara bahasa namun tidak tepat secara fakta (Wu et al., 2025). Melalui penyediaan informasi faktual yang relevan dari hasil penelusuran basis data eksternal, RAG dapat memverifikasi dan melandasi respons yang dihasilkan oleh model (Wu et al., 2025). Selain akurasi, RAG menawarkan mekanisme yang efisien untuk menangani isu pembaruan pengetahuan yang menjadi tantangan besar bagi model bahasa parametrik. Pada model tradisional, memperbarui pengetahuan yang tersimpan dalam memori internal memerlukan proses pelatihan ulang atau *fine-tuning* dengan data baru yang merupakan proses mahal dan lambat. Sebaliknya, RAG mengatasi masalah ini cukup dengan memperbarui basis data pengetahuan eksternal, sehingga model dapat langsung mengakses informasi terkini tanpa perlu modifikasi parameter model yang ekstensif (Wu et al., 2025). RAG juga memiliki keunggulan dalam menyediakan keahlian domain spesifik yang sering kali tidak dimiliki oleh LLM umum. Pelatihan LLM khusus domain biasanya membutuhkan tenaga kerja yang besar untuk pengumpulan dataset, namun RAG memungkinkan konversi LLM umum menjadi spesialis domain hanya dengan membangun dan memanfaatkan basis data pengetahuan yang relevan dengan bidang tersebut (Wu et al., 2025).

II.5.2 **Limitasi Teknis RAG**

Meskipun RAG menawarkan solusi signifikan untuk meningkatkan akurasi LLM, terdapat beberapa limitasi teknis yang perlu diperhatikan dalam implementasinya:

1. Ketidaksinkronan antara proses *Retrieval* dan *Generation* dapat terjadi karena keduanya merupakan proses terpisah, yang berpotensi menyebabkan masuknya informasi yang tidak relevan ke dalam konteks (Gao et al., 2023).

2. Proses *retrieval* yang dijalankan secara independen untuk setiap kueri terkadang mengabaikan konteks percakapan sebelumnya (*history*), yang dapat mengurangi relevansi jawaban dalam sesi dialog panjang.
3. Sifat statis dari hasil *retrieval* dalam satu putaran interaksi berarti jika informasi yang diambil kurang tepat, sistem sulit untuk melakukan koreksi otomatis tanpa intervensi kueri baru (Gao et al., 2023).

Proses Retrieval Augmented Generation secara umum dapat digambarkan melalui diagram sebagai berikut:

Gambar II.4 Rangkaian proses implementasi Retrieval Augmented Generation.

II.5.3 RAG Dalam Domain Medis

Penerapan RAG di bidang kesehatan (*Medical RAG*) bertujuan mengatasi keterbatasan LLM dalam menghasilkan informasi medis yang akurat dan konsisten secara faktual (Amugongo et al., 2025). Tinjauan sistematis terbaru menunjukkan bahwa RAG secara signifikan mengurangi risiko halusinasi dengan membatasi respons model hanya pada dokumen klinis atau pedoman medis terpercaya yang tersedia di basis data (Liu et al., 2025). Mekanisme ini memastikan bahwa saran yang dihasilkan sistem memiliki landasan bukti (*evidence-grounded*) yang dapat diverifikasi demi keselamatan pasien.

Tantangan utama dalam implementasi *Medical RAG* meliputi adanya "kebisingan pencarian" dan kompleksitas terminologi medis yang sangat bervariasi (Liu et al., 2025). Sistem RAG medis yang efektif sering menggunakan strategi pencarian hibrida, menggabungkan pencarian kata kunci untuk istilah spesifik dan pencarian semantik untuk memahami konteks gejala (Amugongo et al., 2025).

II.5.4 Retrieval Augmented Generation Assessment (RAGAS)

Evaluasi terhadap model *Large Language Model* (LLM) yang terintegrasi dalam arsitektur *Retrieval Augmented Generation* (RAG) menghadirkan tantangan tersendiri karena metrik tradisional seperti BLEU atau ROUGE tidak lagi memadai untuk mengukur koherensi semantik dan akurasi faktual (Gao et al., 2023). Dalam konteks sistem prediksi risiko hipertensi, kesalahan halusinasi atau ketidaktepatan pengambilan konteks medis dapat berakibat fatal sehingga diperlukan kerangka evaluasi yang lebih ketat (Liu et al., 2024).

Retrieval Augmented Generation Assessment atau RAGAS muncul sebagai kerang-

ka kerja evaluasi standar yang dirancang untuk mengukur kinerja saluran RAG secara referensi-bebas atau *reference-free* dengan memanfaatkan LLM sebagai juri penilai (Es et al., 2023). Pendekatan RAGAS memisahkan proses evaluasi menjadi dua komponen utama yaitu evaluasi terhadap kemampuan pencarian informasi atau *retrieval* dan evaluasi terhadap kualitas teks yang dibangkitkan atau *generation* (Chen et al., 2024).

Kerangka kerja RAGAS menyediakan berbagai metrik yang dikategorikan berdasarkan fokus evaluasinya yang terbagi menjadi metrik berbasis komponen (*component-wise*) dan metrik ujung-ke-ujung (*end-to-end*).

Gambar II.5 Taksonomi Metrik Evaluasi dalam Framework RAGAS.

Berdasarkan taksonomi di atas, metrik *Faithfulness* dan *Answer Relevancy* digunakan untuk menilai kualitas generasi teks sedangkan *Context Precision* dan *Context Recall* digunakan untuk menilai kualitas pengambilan dokumen (Es et al., 2023).

1. **Faithfulness:** Mengukur konsistensi faktual dari jawaban yang dihasilkan terhadap konteks yang diberikan untuk memastikan tidak ada informasi yang dibuat-buat atau halusinasi yang sangat berbahaya dalam domain kesehatan (Min et al., 2023).
2. **Answer Relevancy:** Menilai seberapa langsung jawaban tersebut merespons pertanyaan pengguna tanpa memperhitungkan kebenaran faktualnya (Wang et al., 2023).
3. **Context Precision:** Mengukur rasio informasi relevan yang berhasil diambil dibandingkan dengan total informasi yang diambil yang menunjukkan efisiensi sistem dalam menyaring *noise* data medis (Gao et al., 2023).
4. **Context Recall:** Mengukur kemampuan sistem untuk mengambil seluruh informasi yang diperlukan dari basis pengetahuan untuk menjawab pertanyaan pengguna (Liu et al., 2024).

Selain metrik per komponen, terdapat juga metrik *Answer Semantic Similarity* dan *Answer Correctness* yang memberikan gambaran performa sistem secara keseluruhan (Es et al., 2023). Proses kerja RAGAS dalam melakukan evaluasi melibatkan alur data yang sistematis di mana data input diproses melalui *retriever* dan *generator* sebelum akhirnya dinilai oleh evaluator.

Gambar II.6 Alur Kerja Evaluasi Sistem RAG Menggunakan RAGAS.

Gambar II.6 memperlihatkan bahwa evaluator bekerja secara iteratif untuk memberikan skor kuantitatif pada setiap tahapan (Saad-Falcon et al., 2024). Penggunaan LLM sebagai evaluator dalam RAGAS terbukti memiliki korelasi yang tinggi dengan penilaian manusia namun dengan efisiensi waktu dan biaya yang jauh lebih rendah dibandingkan evaluasi manual oleh ahli medis (Chen et al., 2024). Dalam pengembangan sistem prediksi hipertensi ini, skor dari RAGAS akan menjadi indikator utama untuk validasi model sebelum sistem diuji coba secara klinis (Huang et al., 2023). Penting untuk dicatat bahwa RAGAS juga memperkenalkan metrik *Context Entity Recall* yang sangat relevan untuk ekstraksi entitas medis seperti nama obat atau kondisi komorbiditas hipertensi (Es et al., 2023). Kehadiran metrik ini memastikan bahwa entitas spesifik yang krusial tidak hilang selama proses pengambilan konteks (Liu et al., 2024). Dengan demikian implementasi RAGAS dalam penelitian ini tidak hanya berfungsi sebagai alat ukur tetapi juga sebagai mekanisme umpan balik untuk melakukan *fine-tuning* pada komponen *retriever* dan *prompt engineering* pada komponen *generator* (Gao et al., 2023).

II.6 Tinjauan Penelitian Sebelumnya

Penelitian mengenai prediksi hipertensi telah mengalami evolusi signifikan dalam setengah dekade terakhir, bergerak dari metode statistik konvensional menuju pendekatan *Machine Learning* (ML) dan *Deep Learning* (DL) yang lebih kompleks. Fokus utama dari berbagai studi terkini adalah meningkatkan akurasi prediksi dini untuk mencegah komplikasi kardiovaskular yang lebih serius (El-Salamony & El-Taweel, 2023). Namun, tren terbaru menunjukkan bahwa akurasi tinggi saja tidak lagi cukup dalam implementasi klinis; transparansi model melalui *Explainable Artificial Intelligence* (XAI) dan kemampuan interaksi natural melalui *Large Language Model* (LLM) menjadi kebutuhan mendesak untuk meningkatkan kepercayaan tenaga medis dan pasien terhadap sistem (Clusmann dkk., 2023). Sebagian besar penelitian yang dilakukan antara tahun 2019 hingga 2021 masih berfokus pada perbandingan algoritma klasifikasi standar. Sebagai contoh, penggunaan metode *ensemble learning* seperti *Random Forest* dan *Gradient Boosting* terbukti secara konsisten mengungguli model tunggal seperti *Decision Tree* atau *Logistic Regression* dalam menangani dataset kesehatan yang tidak seimbang (Kusuma & Hartanto, 2022). Meskipun performanya tinggi, model-model ini sering kali bersifat *black-box* atau sulit diinterpretasikan, yang menjadi hambatan utama dalam adopsi klinis karena dokter perlu memahami alasan di balik prediksi risiko pasien. Merespons keterbatasan tersebut, gelombang penelitian selanjutnya mulai mengintegrasikan metode XAI. Penggunaan *SHapley Additive exPlanations* (SHAP) dan *Local Interpretable*

Model-agnostic Explanations (LIME) telah menjadi standar baru dalam memvisualisasikan kontribusi fitur, seperti pengaruh indeks massa tubuh (BMI) atau kadar glukosa terhadap prediksi hipertensi secara spesifik untuk setiap individu (Miao dkk., 2022). Integrasi ini memungkinkan sistem tidak hanya memberikan label ”Beresiko” atau ”Tidak Beresiko”, tetapi juga memberikan wawasan klinis mengenai variabel mana yang harus diintervensi. Lebih lanjut, kemunculan arsitektur *Transformer* dan *Large Language Models* (LLM) membuka peluang baru dalam pengolahan data kesehatan yang tidak terstruktur, seperti catatan medis elektronik (EHR). Studi terbaru menunjukkan bahwa LLM memiliki potensi besar dalam merangkum riwayat pasien dan memberikan rekomendasi kesehatan yang dipersonalisasi, meskipun tantangan terkait halusinasi model dan privasi data masih menjadi perhatian utama (Thirunavukarasu dkk., 2023). Penelitian ini bermaksud mengisi celah tersebut dengan menggabungkan kekuatan prediktif XAI dengan kemampuan naratif LLM.

Untuk memberikan gambaran komprehensif mengenai posisi penelitian ini dibandingkan dengan studi terdahulu, Tabel II.1 menyajikan ringkasan kritis dari empat penelitian relevan yang dipublikasikan dalam kurun waktu lima tahun terakhir.

Tabel II.1 Studi Sebelumnya

No	Judul & Penulis	Metode	Hasil	Keterbatasan
1	Machine Learning for Hypertension Prediction (El-Salamony & El-Taweel, 2023)	Menggunakan algoritma Ensemble Learning (gabungan Decision Tree, Random Forest, dan Naïve Bayes) pada dataset klinis standar.	Model Random Forest memberikan akurasi tertinggi mencapai 98,5 persen dibandingkan algoritma tunggal lainnya dalam memprediksi status hipertensi.	Studi ini hanya berfokus pada metrik performa (akurasi) dan tidak membahas aspek interpretabilitas (XAI), sehingga sulit untuk melacak variabel penyebab utama.

Bersambung ke halaman berikutnya

Tabel II.1 Studi Sebelumnya (lanjutan)

No	Judul & Penulis	Metode	Hasil	Keterbatasan
2	Interpretable Machine Learning for Early Prediction of Hypertension (Miao dkk., 2022)	Menggabungkan model XGBoost dengan metode interpretasi SHAP (SHapley Additive exPlanations) untuk analisis faktor risiko.	Model berhasil mengidentifikasi usia, BMI, dan kadar trigliserida sebagai fitur paling berpengaruh, dengan visualisasi feature importance yang jelas.	Analisis terbatas pada data terstruktur numerik dan belum memanfaatkan data teks atau riwayat medis naratif pasien.
3	Deep Learning Approaches for Blood Pressure Prediction (Cheng dkk., 2021)	Menggunakan Long Short-Term Memory (LSTM) dan Recurrent Neural Networks (RNN) untuk data time-series tekanan darah.	LSTM menunjukkan performa superior dalam memprediksi fluktuasi tekanan darah jangka pendek dibandingkan model regresi tradisional.	Kompleksitas komputasi sangat tinggi dan membutuhkan data pemantauan kontinu yang sulit didapatkan dalam pemeriksaan rutin biasa.
4	Large Language Models in Medicine (Thirunavukarasu dkk., 2023) (Thirunavukarasu dkk., 2023)	Tinjauan sistematis dan eksperimen awal penggunaan model berbasis Transformer (LLM) untuk dukungan keputusan klinis.	LLM mampu menyintesis informasi medis kompleks menjadi saran yang mudah dipahami oleh pasien dan tenaga medis.	Rentan terhadap bias data pelatihan dan "halusinasi" fakta, serta belum diintegrasikan secara penuh dengan model prediksi numerik (seperti prediksi risiko hipertensi).

Bersambung ke halaman berikutnya

Tabel II.1 Studi Sebelumnya (lanjutan)

No	Judul & Penulis	Metode	Hasil	Keterbatasan
5	Prediction of Personalised Hypertension Using Machine Learning in Indonesian Population (Septian dkk., 2025)	Mengkomparasi algoritma (termasuk LightGBM dan XGBoost) pada 9,58 juta data SA-TUSEHAT dengan analisis fitur menggunakan SHAP (SHapley Additive exPlanations)	Model <i>LightGBM</i> mencapai performa terbaik dengan AUC 0.78 (tanpa riwayat pasien) dan 0.85 (dengan riwayat pasien), di mana usia dan lingkaran pinggang menjadi fitur prediktor dominan.	Studi bersifat <i>cross-sectional</i> sehingga tidak dapat menyimpulkan kausalitas, serta data terbatas pada seting non-rumah sakit yang tidak mencakup variabel klinis mendalam seperti status pengobatan rinci.